



TERRA

O MÉTODO E O LIMITE

Manual científico do TERRA: a definição de cada produto, a resolução real da fonte, e o que o número não sustenta

A entrada do modelo

As cenas, as bandas e o espaço em que ele foi treinado

A discordância

Quantidade contra alocação, e a concordância por blocos

O limite do produto

A grade do mapa, contra o que a fonte resolve

Sumário

Prefácio	v
Lista de siglas	vii
I O dado e o protocolo	1
1 O que o TERRA entrega, e de onde vem	2
1.1 A linha, e o que dela chega ao produto	2
1.2 O que valida cada produto	2
1.3 O que a linha tem, e o TERRA ainda não	3
1.4 O que o TERRA não é	3
2 O protocolo comum: área, catálogo e janela	5
2.1 A área de interesse	5
2.2 O catálogo e a forma da leitura	5
2.3 A janela de aquisição e a cadência	6
2.4 As 22 datas, e o que acontece fora delas	6
2.5 Os caminhos neurais leem uma cena, não a série	7
2.6 Qual produto lê o quê	7
2.7 O que não se pode afirmar	8
3 Do número gravado ao número que o modelo vê	9
3.1 A conversão física	9
3.2 O espaço em que os modelos aprenderam	9
3.3 O que isso muda na leitura	10
3.4 O defeito aberto: a cena anterior a 2022	10
3.5 O que não se pode afirmar	11
II Classificação de cobertura	12
4 Os três caminhos de modelo, e a legenda fixa	13
4.1 As cinco classes, e por que são cinco	13
4.2 O caminho spectral: 80 atributos por pixel	13
4.3 Os outros dois caminhos	15
4.4 O que a medição da linha diz sobre a escolha	15
4.5 O que não se pode concluir	16
5 O que o mapa afirma, e em que unidade	17
5.1 O que a execução devolve	17
5.2 As frações de classe, e o denominador	17
5.3 O hectare é uma contagem de pixels	18
5.4 A confiança não é probabilidade de acerto	18
5.5 O modo Temporal	18

5.6	O que não se pode concluir	19
III	Erro, concordância e transferência	20
6	Concordância com o MapBiomias: a matriz e seus intervalos	21
6.1	A unidade de amostragem é a célula, não o pixel	21
6.2	A matriz, e as três acurácias	22
6.3	O intervalo é de Wilson, não de Wald	22
6.4	O que fica fora da conta	23
6.5	Kappa não é reportado	23
6.6	O que não se pode concluir	23
7	Quantidade e alocação: dois erros que não se somam	24
7.1	As duas parcelas	24
7.2	O mesmo desacordo, dois diagnósticos opostos	24
7.3	O que cada parcela pede	25
7.4	Kappa não é reportado	25
7.5	O que não se pode concluir	26
8	Concordância por blocos: onde a discordância está	27
8.1	A grade	27
8.2	O que é reportado, e por que não é uma média	27
8.3	O mesmo número global, duas paisagens	27
8.4	Não é um teste	28
8.5	O que não se pode concluir	28
9	Separabilidade de classes: contraste e assinatura	30
9.1	De onde saem os números	30
9.2	A distância, e por que ela satura	30
9.3	O que a escala exige do dado	31
9.4	As duas leituras, que não andam juntas	31
9.5	O melhor de sete, e não a média	31
9.6	O que é recusado, e por quê	32
9.7	O que não se pode concluir	32
10	Deslocamento de domínio: o diagnóstico	33
10.1	A impressão digital	33
10.2	As quatro medidas	33
10.3	Por que o núcleo do MMD é gaussiano	34
10.4	A tabela por atributo	34
10.5	O que não se pode concluir	35
11	Deslocamento de domínio: o que ele não corrige	36
11.1	Seis correções, nenhuma funcionou	36
11.2	A correção física ganha num lugar e perde no outro	36
11.3	Duas armadilhas medidas no caminho	36
11.4	O que reinterpreto todo o resto	38
11.5	O que não se pode concluir	38
IV	Água e terreno	39
12	Água superficial por índice espectral	40

12.1	Os três índices	40
12.2	O limiar por data	41
12.3	As duas correções que decidem o produto	41
12.4	Persistente e efêmero	42
12.5	O que não se pode concluir	42
13	A cadeia de terreno: da grade ao HAND	43
13.1	A cadeia, passo a passo	43
13.2	Por que a cadeia é reimplementada	43
13.3	Quatro produtos, uma grade	44
13.4	Por que a janela é maior que a área	44
13.5	O que a cadeia produz	44
13.6	O limiar de drenagem decide o resultado	44
13.7	O que não se pode concluir	45
14	A envoltória: o raster de concordância	47
14.1	O raster de concordância	47
14.2	IoU, que é o CSI da literatura	47
14.3	A discordância não é de borda	49
14.4	O que a saída declara junto dos números	49
14.5	O que não se pode concluir	49
V	Energia	50
15	Recurso solar no ponto	51
15.1	A célula que responde pela área	51
15.2	O que a série mede	51
15.3	Variabilidade entre anos	52
15.4	Inclinação ótima e a tolerância a desvio	53
15.5	Do plano inclinado ao rendimento	53
15.6	Duas aferições independentes	54
15.7	A temperatura de módulo depende do vento da reanálise	55
15.8	O que não se pode concluir	56
16	O modelo de energia e a cascata de perdas	57
16.1	Três razões de desempenho, e uma aferição	57
16.2	A cascata: o que é medido e o que é declarado	57
16.3	A maior perda medida, e o vento na altura errada	59
16.4	Degradação é base de relato, e não linha de perda	59
16.5	Rastreamento: a resposta inverte com a base	60
16.6	Quando a energia chega	61
16.7	Da área à capacidade, e a base que decide	61
16.8	A banda de excedência, e o que ela não contém	62
16.9	O que não se pode concluir	62
	Referências	64
A	As ações do sidecar	66
B	Procedência, capítulo a capítulo	68

Prefácio

Há duas perguntas que se fazem a uma ferramenta de sensoriamento remoto, e elas não têm a mesma resposta. A primeira é *onde clico*. A segunda vem depois de o resultado aparecer na tela: *o que exatamente eu estou olhando?*

O *Guia do usuário* do TERRA responde à primeira. Ele cobre como se desenha uma área, como se põe a janela de aquisição na trilha, o que cada painel do Studio mostra e o que fazer quando o interpretador Python não importa o que o sidecar precisa. É um documento de operação, e para operar a aplicação é o que basta.

Este livro responde à segunda. Ele existe para quem, olhando um mapa classificado, pergunta o que o modelo está errando e onde; que espectro ele observou para decidir aquilo; se aquele número resolve a área desenhada ou a célula de um grau em que ela caiu. A tela mostra o resultado. Ela não mostra a definição da métrica, a resolução real da fonte, nem o ponto além do qual o número deixa de significar o que parece significar.

Nada disso cabe num *tooltip*. E nada disso é opcional para quem vai usar o resultado em vez de apenas olhá-lo.

De que versão fala. Do TERRA 0.4.0, 9c8cad0, de 23 de agosto de 2026. Onde o texto descreve um comportamento do código, é o dessa versão. Onde descreve um defeito ainda aberto, diz que está aberto e diz o que muda quando a correção entrar.

A quem se dirige. A quem usa o TERRA para uma análise e quer entender o que a aplicação fez com o dado. Pressupõe familiaridade com sensoriamento remoto e com a leitura de um método; não pressupõe conhecimento do código da aplicação. Onde uma formulação é citada, ela vem com a referência e sem o desenvolvimento.

Por que ele existe. Por transparência. O TERRA devolve mapa, tabela e figura, e quase toda decisão que produziu esses três está fora da tela: que cenas entraram, em que espaço o modelo leu as bandas, o que a concordância compara, onde a fonte resolve e onde não resolve. Um resultado cuja construção não pode ser inspecionada é um resultado que só cabe aceitar ou recusar.

O que não cobre. A instalação e a operação da interface, que estão no *Guia do usuário*. Nenhum roteiro de tela é repetido aqui.

Também não cobre a derivação completa dos métodos, que fica nos relatórios de estudo da linha *TERRA-Research*. Cada capítulo nomeia o estudo em vez de reescrevê-lo. Um manual que reproduz a derivação envelhece junto com ela, e passa a discordar da fonte na primeira revisão.

Como está organizado. Sete partes, uma por família de produto, depois de uma primeira sobre o que é comum a todas. Dentro de cada parte, um capítulo por pergunta que se responde separadamente.

Os apêndices são consulta: o catálogo de ações do sidecar e a tabela de procedência. Ficam no fim porque o leitor volta a eles com uma pergunta pontual, e não os lê em ordem. As tabelas curtas que sustentam o argumento do parágrafo ao lado ficaram onde estavam.

Como cada capítulo está organizado

Todos seguem a mesma ordem, para que quem já leu um saiba onde procurar nos outros:

A pergunta. o que o capítulo decide, em uma frase.

Tabela 1: A divisão entre os dois manuais, pergunta a pergunta. A coluna da esquerda é o *Guia do usuário*; a da direita, este documento.

Guia do usuário	Este livro
onde está o controle que valor digitar no campo como se lê a legenda	o que ele calcula por que o padrão é aquele valor em que unidade o número está, e sobre que amostra
o que a mensagem de erro quer como instalar e atualizar	qual é a resolução real da fonte até onde o número vai, e a referência que o fixa

A definição. a matemática, quando existe, com a referência que a fixou. Fórmula e não descrição: “*índice de água normalizado*” não diz qual banda entra no numerador, e duas implementações que se descrevem com a mesma frase podem devolver números diferentes.

O que o TERRA faz com ela. os parâmetros que a aplicação expõe, os valores padrão, e o que aparece na tela como resultado.

O que não se pode afirmar. o limite, com número quando há número.

A procedência de cada afirmação não fica no capítulo: as 119 entradas estão juntas no apêndice B, com o arquivo que implementa, o estudo que mediu ou a referência que fixou, e uma coluna que diz se aquilo é código público, estudo da linha ou literatura. Dezesseis listas repartidas em dezesseis capítulos são a mesma consulta, e quem confere de onde um número saiu procura uma entrada, não lê um capítulo.

Um manual que só diz o que o produto faz transfere ao leitor a tarefa de descobrir onde ele para. Essa descoberta costuma vir tarde, e por um resultado que não fechou.

Convenções

Rótulos em inglês. a interface do TERRA está em inglês, e os rótulos são citados como estão na tela. Traduzi-los faria o leitor procurar um controle que não existe.

Vírgula decimal no texto, ponto no código. 3,5 cm no corpo, 0.035 quando o valor é literal de um arquivo.

Procedência com arquivo e linha. uma referência como `sidecar/flood.py:506` é do repositório *geosense-infer*, na versão declarada acima. Linha muda; o nome da função, que o texto sempre dá junto, não.

Estudos pelo apelido. E-hand-flood-baseline é um estudo da linha *TERRA-Research*, e é assim que o texto se refere a ele. O apelido é estável; a organização interna da linha não, e já foi reagrupada uma vez.

A linha é privada. *TERRA-Research* reúne os estudos que sustentam o que o TERRA entrega, e não é distribuída publicamente: o código, os dados intermediários e os relatórios ficam sob acesso restrito enquanto a linha trabalha neles. Um estudo nomeado neste livro pode ser solicitado, e a seção 1.1 diz para quem. O que é público é a aplicação, sob GPL v3, com o sidecar que este livro cita arquivo por arquivo.

Lista de siglas

Só o que o texto usa mais de uma vez. Sigla que aparece uma vez só está definida no ponto em que aparece; esta lista serve a quem lê fora de ordem.

BOA	<i>Bottom of atmosphere</i> , a refletância de superfície depois da correção atmosférica
CSI	<i>Critical success index</i> , o nome que a literatura de inundação dá ao índice de Jaccard entre duas máscaras binárias
DEM	<i>Digital elevation model</i> , o modelo digital de elevação
DHI	<i>Diffuse horizontal irradiance</i> , a irradiação difusa no plano horizontal
DN	<i>Digital number</i> , o inteiro gravado no produto, antes de qualquer conversão para refletância. É como o texto e o código o escrevem, inclusive na equação (3.1)
DNI	<i>Direct normal irradiance</i> , a irradiação direta medida num plano normal ao feixe solar
GHI	<i>Global horizontal irradiance</i> , a irradiação global no plano horizontal, somando feixe direto e céu difuso
HAND	<i>Height above the nearest drainage</i> , a altura de uma célula acima da drenagem para a qual ela escoar
IoU	<i>Intersection over union</i> , o índice de Jaccard entre duas máscaras. Numericamente o mesmo que o CSI
L2A	Nível de processamento do Sentinel-2 que entrega refletância de superfície. O L1C, anterior a ele, entrega refletância de topo de atmosfera
MERRA-2	<i>Modern-Era Retrospective analysis for Research and Applications, version 2</i> , a reanálise de onde vem a meteorologia do POWER
NDVI	<i>Normalized difference vegetation index</i>
POWER	<i>Prediction of Worldwide Energy Resources</i> , o serviço de séries meteorológicas da NASA
STAC	<i>SpatioTemporal Asset Catalog</i> , o padrão de catálogo pelo qual a aplicação descobre as cenas
SYN1DEG	O produto de fluxos do CERES, em célula de um grau, de onde vem a radiação do POWER

Parte I

O dado e o protocolo

O que o TERRA entrega, e de onde vem

O TERRA entrega cinco famílias de produto sobre a mesma área desenhada: cobertura do solo, água superficial, envoltória de cheia, energia e dossel. Elas saem da mesma tela, na mesma sessão, com a mesma aparência de resultado.

Não são validadas do mesmo modo, e a diferença não aparece em lugar nenhum da interface. Ela determina, produto por produto, até onde o número vai.

1.1 A linha, e o que dela chega ao produto

O TERRA não é onde os métodos são desenvolvidos. Ele é a ponta de uma linha de pesquisa, *TERRA-Research*, que roda o ciclo completo: revisão da literatura, protocolo registrado antes da execução, simulação contra dado adquirido, e relatório.

problema → pesquisa → resultado → TERRA

A cadeia começa num **problema**, e não numa ideia de funcionalidade. A **pesquisa** o ataca sob protocolo, e o que ela produz é um **resultado**, que pode ser positivo ou negativo. Só o último elo é opcional: um resultado é embarcado quando estabilizou e quando põe algo útil na mão de quem usa a aplicação.

Por isso a linha tem mais resultado do que a aplicação tem funcionalidade. Três motivos, todos legítimos:

O resultado é negativo. um estudo que mede que um caminho não funciona impede a aplicação de prometer o que não entrega. É o serviço mais direto que a linha presta ao produto, e por definição não vira tela.

O resultado é bom e ainda não foi embarcado. embarcar custa interface, teste e empacotamento. A fila é decidida por uso, não por maturidade.

O resultado não é do escopo do TERRA. a linha responde perguntas que a aplicação não se propõe a responder.

TERRA-Research é privada. Código, dado intermediário e relatório ficam sob acesso restrito enquanto a linha trabalha neles.

Todo estudo nomeado neste livro pode ser solicitado, e o pedido não precisa de justificativa formal: escreva para joao_leonardi.melo@somosicev.com dizendo qual estudo e para quê. A aplicação é pública, sob GPL v3, e é dela que vêm as referências de arquivo deste livro.

1.2 O que valida cada produto

A pergunta não é se existe um estudo dedicado ao produto. É o que sustenta o número. Uma cadeia física publicada e implementada com fidelidade sustenta tanto quanto um estudo próprio, e às vezes mais. O que muda entre as linhas abaixo é a natureza da validação, e é ela que fixa até onde o número vai.

Duas linhas pedem leitura atenta, porque são as que mais se prestam a ser lidas além do que sustentam.

Energia eólica. a cadeia é publicada e a implementação é fiel, mas nada nela foi comparado com anemômetro. Toda figura de turbina é bruta de esteira, disponibilidade, perda elétrica, gelo,

Tabela 1.1: O que valida o número de cada produto, e até onde essa validação o leva.

Produto	O que valida o número	Até onde ele vai
Cobertura do solo	protocolo publicado (Melo et al., 2026), e a concordância com o MapBiomias medida em cada execução	resultado, lido com as ressalvas de legenda fixa e de referência
Concordância e erro	definições correntes de acurácia temática, computadas sobre a própria execução	número reproduzível, com a definição neste livro
Água superficial	três índices publicados e limiar de Otsu por data, sem modelo treinado	o índice, pela fonte original que o define
Envoltória de cheia	a discordância entre quatro produtos de elevação, medida pela linha em E-hand-flood-baseline	a envoltória; a mancha de um produto só, não
Energia solar	cadeia física em pvlib, aferida contra o Global Solar Atlas, com o coeficiente de desempenho declarado	triagem quantificada
Energia eólica	cadeia física publicada, de Weibull à curva da turbina de referência, sem aferição contra medição de vento	triagem, e só com os diagnósticos ao lado
Dossel	inversão de Beer-Lambert, com o viés do caminho analítico medido em E-architecture-vs-slab	comparação entre cenários, não valor absoluto

sujeira e restrição de despacho. E repousa sobre extrapolação acima do nível mais alto que a reanálise carrega. O módulo carrega essa qualificação no próprio resultado, e a aplicação a exibe ao lado dos números. Um resultado eólico do TERRA responde se vale a pena medir aquele sítio. Não responde quanto aquele sítio produz.

Envoltória de cheia. o produto é a envoltória, e não a mancha. O estudo que a fundamenta mediu que dois modelos de elevação de 30 m discordam sobre cerca de 21 % das células no limiar mais apertado. Tomar a mancha de um produto só é tomar uma forma que muda com a escolha do produto, e a tela não avisa qual parte dela é terreno e qual é escolha.

1.3 O que a linha tem, e o TERRA ainda não

Quem usa a aplicação acaba perguntando o que mais a linha mede, e o que ainda não chegou à tela. A lista abaixo é o estado em agosto de 2026, e muda entre edições. Quando um item sair dela por ter sido embarcado, o capítulo do produto passa a cobri-lo. Quando sair por ter sido descartado, esta seção passa a dizer por quê.

A frente de solo é a mais adiantada entre as abertas, e vale dizer com que ressalva. A coleta de campo está fechada, com 11 394 amostras sobre 47 sítios e 477 parcelas, entre 2017 e 2024. A cobertura não é uniforme. Os grupos de ácidos graxos e o pH estão em 100 % das amostras; o carbono orgânico e o nitrogênio, em 19 %. Isso enfraquece exatamente o conjunto de variáveis contra o qual a hipótese principal é testada, e a conclusão terá de ser lida com esse limite.

1.4 O que o TERRA não é

O TERRA foi construído para o estudo detalhado de áreas particulares, da escala de propriedade à de paisagem, sob um protocolo fixo. Não é um SIG de uso geral. Não cobre o terreno que o

Tabela 1.2: Frentes da linha *TERRA-Research* sem funcionalidade correspondente na aplicação, com o estado de cada uma em agosto de 2026.

Frente	O que mede	Estado
Cota e volume de açude sem posto	lâmina d'água por altimetria orbital, e curva área-elevação pareada a extensões Sentinel-2	fechada, com relatório; quatro estudos encadeados
Defasagem fenológica entre regiões	quantos dias uma lavoura está atrás da outra, por dois métodos independentes que concordam	fechada, com resultado direto ao usuário
Solo e comunidade microbiana	quanto da relação publicada entre espectro e microbiologia do solo sobrevive a controles de cobertura, geografia e autocorrelação espacial	em andamento, com protocolo registrado antes da execução
Correção de deslocamento de domínio	seis métodos de adaptação sobre um par real de regiões	fechada, negativa; o diagnóstico entrou no TERRA, a correção não
Rugosidade por máscara de extensão	se a extensão observada de uma cheia identifica o coeficiente de Manning	fechada, negativa

Earth Engine e o QGIS já cobrem.

Três consequências que aparecem cedo para quem vem daquelas ferramentas:

A legenda de saída é fixa. os modelos de cultura emitem cinco classes do MapBiomas e nada além. Uma área em outro bioma pode devolver resultado confiante e semanticamente errado, e é por isso que o diagnóstico de deslocamento de domínio existe no produto.

Não há álgebra de mapas nem edição de camada. o que a aplicação calcula está nas 17 ações do sidecar, catalogadas no apêndice A. A extensão se faz exportando as tabelas.

Nada é enviado para servidor. a aplicação roda local, sem conta e sem serviço. As imagens são lidas por demanda do catálogo, apenas a janela do polígono e as bandas necessárias.

O protocolo comum: área, catálogo e janela

Uma área desenhada no TERRA pode ser classificada, ter a água mapeada, receber uma envoltória de cheia, um recurso solar e um dossel simulado. Cinco produtos sobre uma área, que é natural ler como cinco leituras do mesmo dado.

Não são. Dois deles leem o Sentinel-2, um lê quatro modelos de elevação e um lê uma reanálise meteorológica em célula de grau. O quinto não lê nada de novo: consome o que outro já produziu. O que segue é a parte comum aos cinco, e é contra ela que cada capítulo adiante diz onde o seu produto se afasta.

2.1 A área de interesse

A área é um polígono em EPSG:4326, desenhado no mapa ou importado. Ela faz três coisas, e nas três é o polígono, não a sua caixa envolvente, que manda:

Define a consulta ao catálogo. a busca é por interseção com o polígono.

Recorta a leitura. as bandas são lidas apenas na janela do polígono, e não na cena inteira.

Delimita a estatística. toda contagem, área, fração e concordância é tomada sobre as células internas ao polígono.

A terceira parece óbvia e não é. Na envoltória de cheia, a cadeia de terreno precisa da área contribuinte a montante, e por isso roda numa janela *maior* que a área, de 2 a 5 km além dela. O relatório, ainda assim, é tomado só dentro do polígono.

Resumir a janela ampliada em vez do polígono inflava cada figura. Numa execução observada, uma janela de 277×291 células de 30,8 m punha áreas de classe somando $76,2 \text{ km}^2$, contra uma área de interesse de cerca de 20 km^2 . Fator de quase quatro.

2.2 O catálogo e a forma da leitura

A fonte óptica é o *Microsoft Planetary Computer*, coleção sentinel-2-l2a, consultada por **STAC**, o *SpatioTemporal Asset Catalog*. As bandas são lidas por demanda como *Cloud-Optimized GeoTIFF*: a janela do polígono e as bandas necessárias, e nada mais. Não existe download de produto SAFE completo em nenhum caminho da aplicação.

Tabela 2.1: As bandas que uma execução de classificação coleta. A cena não é descartada quando falta uma banda extra — ela apenas deixa de servir aos caminhos que a exigem.

Grupo	Bandas	Para quê
Exigidas	B02, B03, B04, B08	o Random Forest espectral; sem elas a cena não entra
Extras	B8A, B11, B12	os seis canais do caminho Prithvi e do <i>Temporal Transformer</i>

As bandas não vêm todas na mesma resolução nativa — B02 a B08 a 10 m, B8A, B11 e B12 a 20 m — e são reprojatadas para a grade de referência da execução por reamostragem bilinear.

Reamostrar B11 de 20 m para uma grade de 10 m não cria informação de 10 m. Um mapa desenhado nessa grade tem célula de 10 m e conteúdo de 20 m nas bandas do infravermelho de ondas curtas. Uma feição menor que 20 m que apareça ali é do interpolador. Isto vale para qualquer produto que use as bandas extras.

2.3 A janela de aquisição e a cadência

A janela é o par de datas que o usuário arrasta na trilha ao pé do mapa. Dois parâmetros a acompanham:

max_cloud. a cobertura de nuvem máxima aceita por cena, do campo `eo:cloud_cover` do catálogo. A interface oferece 40 % como padrão; o sidecar, chamado direto, aceita até 100 %.

monthly_best. ligado por padrão. Mantém, de cada mês calendário, apenas a cena de menor cobertura de nuvem.

O segundo não é uma conveniência de desempenho. Ele aproxima a cadência de cerca de uma cena por mês do conjunto de 22 datas com que os modelos foram ajustados. Com ela, as estatísticas temporais que alimentam o classificador ficam comparáveis às que ele viu no treino.

Desligá-lo entrega todas as cenas abaixo do limite de nuvem. É útil para uma série descritiva de água, e é um descasamento para o classificador.

2.4 As 22 datas, e o que acontece fora delas

O bloco de curva crua do Random Forest espectral tem comprimento fixo. São 22 posições, derivadas do próprio artefato: `n_dates_model` é o número de nomes de *feature* menos 58, que é onde o bloco de NDVI começa. Uma janela que produza número diferente de datas é ajustada a esse comprimento, e o ajuste não é simétrico.

Tabela 2.2: O que a aplicação faz quando a janela não devolve exatamente 22 datas. Nos dois casos o modelo recebe um vetor de comprimento 22 e não tem como distinguir uma posição preenchida de uma medida.

Datas obtidas	O que o código faz	O que o modelo recebe
mais de 22	mantém as últimas 22	a curva crua do fim da janela; o começo é descartado
menos de 22	completa com zeros	posições de valor zero, indistinguíveis de NDVI medido igual a zero

Alargar a janela não dá mais curva crua ao classificador. Dá estatísticas de banda e descritores de índice calculados sobre mais datas, que usam todas, e um bloco de NDVI que passa a descartar o início do período.

Duas execuções sobre a mesma área com janelas diferentes não diferem apenas em quantidade de observação. Diferem em *qual* parte da série chega crua ao modelo. Uma comparação entre elas precisa dizer isso, ou atribui à área o que é da janela.

O caminho de menos de 22 datas é o mais delicado. Uma janela curta o suficiente para render menos de 22 cenas úteis produz um resultado que a aplicação não recusa, e que o modelo lê como se a lavoura tivesse NDVI zero no trecho ausente. Não há medida, neste repositório, de quanto isso custa em acurácia. Há a constatação de que acontece, e ela basta para conferir o número de datas efetivas antes de ler o mapa. A aplicação reporta esse número na barra de execução e no pacote de exportação.

2.5 Os caminhos neurais leem uma cena, não a série

O *Temporal Transformer* e o Prithvi não consomem a janela como o Random Forest. Ambos tomam a cena do meio do período — literalmente o elemento central da lista ordenada de produtos — e o Prithvi descarta o resto.

A consequência precisa estar em qualquer método escrito com esses caminhos: **alargar o período não dá mais dado ao Prithvi, muda qual aquisição ele lê**. Uma janela de janeiro a dezembro e outra de março a outubro podem devolver mapas diferentes por terem centros diferentes, sem que nada tenha mudado no terreno.

2.6 Qual produto lê o quê

Tabela 2.3: As fontes por produto, com a resolução em que cada uma resolve. É a resolução da fonte, e não a grade em que o resultado é desenhado.

Produto	Fonte	Resolução da fonte
Cobertura do solo	Sentinel-2 L2A , o nível que entrega refletância de superfície, via STAC	10 m; 20 m nas bandas extras
Água superficial	Sentinel-2 L2A, por data	idem
Envoltória de cheia	quatro produtos de elevação: cop-dem-glo-30, nasadem, alos-dem, cop-dem-glo-90	30 m nos três primeiros, 90 m no quarto
Recurso solar no ponto	NASA POWER , <i>Prediction of Worldwide Energy Resources</i> : radiação de SYN1DEG, meteorologia de MERRA-2	1° para radiação; 0,5° por 0,625° para o resto
Irradiação sobre terreno, sítio	cop-dem-glo-30 mais o ponto do POWER	30 m no terreno, 1° na radiação
Modelo de energia	nenhuma nova: consome a cadeia solar	—
Dossel	nenhuma nova: consome a série de índice já calculada	—

Duas leituras dessa tabela importam mais que as outras.

A primeira: os produtos de energia no ponto não resolvem a área. A radiação do POWER está em célula de um grau, e todo ponto dentro de uma área de escala de propriedade devolve a mesma série. O número descreve a célula em que a área está, não estrutura dentro dela. Os mapas de terreno e de sítio são a exceção, e resolvem a 30 m.

A segunda: os dois caminhos que leem elevação não a leem do mesmo modo.

A envoltória de cheia mescla todos os *tiles* que interceptam a janela ampliada. Uma rede de drenagem cortada na borda da área produz HAND alto e mancha pequena: um mapa plausível, errado numa direção que a tela não revela.

A cadeia solar não faz isso. `solar.fetch_dem` lê `items[0]`, o primeiro *tile* devolvido, sem mesclagem. Os *tiles* Copernicus são de um grau, então uma área que atravessasse uma borda recebe um modelo de elevação que cobre parte dela. Para declividade e orientação isso degrada em manchas. É uma limitação dos mapas de irradiação sobre terreno e de sítio fotovoltaico, e não da envoltória de cheia.

2.7 O que não se pode afirmar

Que dois produtos sobre a mesma área estão sobre o mesmo dado. estão sobre a mesma geometria. A tabela 2.3 é a lista das fontes que diferem.

Que a grade do mapa é a resolução do dado. um mapa de água desenhado em célula de 10 m usando MNDWI carrega conteúdo de 20 m na banda B11. Um mapa de irradiação sobre terreno em célula de 30 m carrega radiação de célula de um grau modulada por geometria de 30 m.

Que alargar a janela sempre melhora. para o Random Forest, muda qual trecho da série chega cru. Para o Prithvi, muda qual aquisição é lida. Para a água, aumenta o número de datas, e com ele o denominador das frações de persistência.

Que o número de cenas está fixado pelo protocolo. está fixado pela janela, pelo limite de nuvem, pela disponibilidade do catálogo e pelo filtro mensal. Qualquer método escrito com resultado do TERRA declara os quatro.

Do número gravado ao número que o modelo vê

O Sentinel-2 não distribui refletância. Distribui número digital inteiro, e a refletância sai de uma conversão. Dentro do TERRA essa conversão tem duas versões, uma física e uma histórica, e as duas estão em uso ao mesmo tempo, de propósito.

Quem for ler um valor espectral do TERRA precisa saber qual das duas produziu o número na tela. A diferença entre elas é de 0,1 em toda banda, e nada na interface a indica.

3.1 A conversão física

A *processing baseline* 04.00 vale para produtos gerados a partir de 25 de janeiro de 2022. Nela o Sentinel-2 desloca a faixa dinâmica por uma constante, para que a refletância perto de zero deixe de ser truncada sobre superfícies escuras (ESA, 2021). O deslocamento é gravado nos metadados do produto. Portanto:

$$\rho = \frac{DN + BOA_ADD_OFFSET}{10000}, \quad BOA_ADD_OFFSET = -1000 \quad (3.1)$$

Ler o número digital sem o termo de offset superestima *toda* banda em 0,1. Alguns catálogos harmonizam isso na entrega. O Planetary Computer, que é o que o TERRA lê por padrão, não harmoniza: seus itens não expõem escala nem offset em `reporta:bands`, e a correção fica com a aplicação.

O offset é derivado por produto, e não fixado como constante. Uma cena anterior à mudança não o carrega, e subtrair um offset dela introduziria justamente o erro que a função existe para remover. A decisão usa `s2:processing_baseline` quando o catálogo o reporta, e cai para a data de aquisição quando não.

Tudo o que a aplicação *reporta* como grandeza física passa por aqui: os índices de vegetação, a fenologia, as máscaras de água, as composições de banda e a série que alimenta o dossel.

3.2 O espaço em que os modelos aprenderam

Os artefatos em `model/` não foram ajustados nesse espaço. Foram ajustados sobre entradas construídas como `DN/10000`, sem o termo de offset. O conjunto são 22 produtos Sentinel-2 adquiridos entre 4 de maio de 2024 e 4 de janeiro de 2026, sobre os *tiles* T21JZN e T22JBT.

Todos esses produtos são posteriores à *baseline* 04.00. Ou seja: a imagem de treino carregava o offset e o pipeline de treino não o subtraiu. As cabeças aprenderam um espaço em que toda banda está 0,1 alta, e são coerentes dentro dele.

Nada estava descasado. **Corrigir apenas a inferência é que criaria o descasamento**, e isso está medido. Sobre uma área em Cascavel, converter as entradas do modelo com o offset move 56,8 % dos pixels, e transforma 70,8 % de soja em 62,0 % de formação florestal sobre lavoura. Não é ganho de acurácia. É um modelo respondendo a uma pergunta que nunca lhe foi feita.

Por isso a costura é deliberada e explícita no código: existem duas funções, `to_reflectance` para o que é reportado e `as_trained` para as três entradas de modelo. A costura fecha quando as cabeças forem reajustadas sobre entrada corrigida, e nesse momento `as_trained` é apagada, não alterada.

Tabela 3.1: As duas conversões, com a fórmula de cada uma e quem a consome.

Função	Fórmula	Consumidores
to_reflectance	$(DN + \text{offset})/10000$	índices de vegetação, fenologia, máscaras de água, composições e série do dossel: tudo o que a tela chama de refletância
as_trained	$DN/10000$	as três entradas de modelo: Random Forest espectral, <i>Temporal Transformer</i> , Prithvi

3.3 O que isso muda na leitura

Um valor de refletância lido no painel espectral não é a entrada do classificador. para uma cena pós-baseline, a entrada do modelo está 0,1 acima do valor exibido, em todas as bandas. Comparar um número do painel com um limiar tirado da literatura de modelos é legítimo; comparar com o que a cabeça recebeu, não.

Os índices normalizados não se salvam pela normalização. um NDVI calculado com offset e outro sem não diferem por um fator. Diferem por um termo que não se cancela: o offset entra igual no numerador e no denominador, e não igual no resultado. O NDVI que a aplicação relata usa a conversão física; o bloco de NDVI cru que o Random Forest consome, não.

A separabilidade e o deslocamento de domínio herdaram o espaço de treino. as impressões digitais gravadas no momento da classificação vivem no espaço de `as_trained`. Isso é o correto para comparar duas execuções entre si, e é o motivo pelo qual esses números não devem ser lidos como refletância.

3.4 O defeito aberto: a cena anterior a 2022

`as_trained` recebe apenas o número digital. Não recebe o produto, e portanto não distingue cena anterior de cena posterior à baseline. Para cena de 2022 em diante isso é exatamente o que se quer. Para cena anterior, é silenciosamente errado por $-0,10$.

Tabela 3.2: Mesmo ponto, mesmo caminho de leitura, dois anos. A diferença é o offset, e é da ordem de 0,1 em toda banda. Uma cena de 2021 entregue a uma cabeça treinada no espaço de 2024 entra deslocada dessa quantidade.

Banda	2021	2024	Δ
B02	0,019 3	0,122 6	0,103 3
B03	0,035 5	0,139 3	0,103 8
B04	0,020 2	0,122 8	0,102 6
B8A	0,300 8	0,406 7	0,105 9
B11	0,148 8	0,250 1	0,101 3
B12	0,062 8	0,161 2	0,098 4

O próprio artefato confirma que o espaço de treino é o deslocado, e não o físico. A média dos pixels válidos das três pilhas de treino é 0,148 0, 0,172 5, 0,184 8, 0,400 7, 0,332 2 e 0,253 6, e a do normalizador gravado no *checkpoint* é 0,150 7, 0,175 5, 0,188 4, 0,404 2, 0,338 2 e 0,259 5.

O tamanho do problema sai do mesmo normalizador. Com desvio de 0,030 9 na primeira posição, alimentar o *Temporal Transformer* com cena de 2021 sem elevá-la ao espaço de treino põe a entrada a cerca de **três desvios** do que ele aprendeu no azul.

Em TERRA 0.4.0 isto não está corrigido: `as_trained` continua com um argumento. A correção proposta é aditiva. Ela passa o produto e cancela o termo quando ele já é pós-baseline, de modo que o comportamento pós-baseline fique idêntico ao de hoje. Está descrita numa nota de correção da linha *TERRA-Research*, com o teste que cobre os dois lados da baseline.

A regra até então. uma classificação cuja janela cai antes de 25 de janeiro de 2022 tem de ser lida sabendo disto. O produto não avisa, o mapa sai plausível, e o erro é de três desvios na banda mais sensível do modelo mais recente. Numa janela que atravessa a data, parte das cenas está no espaço certo e parte não, e a inconsistência fica interna à série.

3.5 O que não se pode afirmar

Que a costura é um erro. a medição diz o contrário, e está na seção 3.2. O que é erro é o caso pré-baseline, e só ele.

Que os dois números são intercambiáveis com uma conta. são, para uma cena única e uma banda: 0,1. Não são, para qualquer grandeza derivada, seja índice normalizado, descritor fenológico ou distância entre distribuições. A diferença não atravessa a derivação como constante.

Que o offset foi harmonizado pelo catálogo. não foi, no Planetary Computer. Um pipeline que leia o mesmo produto de outro catálogo pode receber valores já harmonizados. Nesse caso a conversão da equação (3.1) aplicaria o termo duas vezes.

Parte II

Classificação de cobertura

Os três caminhos de modelo, e a legenda fixa

A tela oferece três modelos e dois modos, e a escolha entre eles muda o mapa. Muda também o que o resultado significa, porque os três não leem o mesmo recorte do dado que o capítulo 2 descreveu. Um consome a série inteira em forma resumida, um consome a série como sequência, e um consome uma única aquisição.

O que os três têm em comum é o vocabulário de saída, e é ele que impõe o limite mais duro da aplicação.

4.1 As cinco classes, e por que são cinco

Os três caminhos emitem os mesmos cinco códigos do MapBiomias, e nada além. O vetor está gravado no próprio artefato, em `model/label_encoder.joblib`:

Tabela 4.1: As cinco classes que qualquer um dos três caminhos pode emitir, com o código MapBiomias correspondente. Um pixel recebe uma destas, sempre.

Código	Classe MapBiomias	Como ler
3	Formação florestal	vegetação arbórea, nativa ou não
21	Mosaico de usos	agricultura e pastagem misturadas na célula
25	Área não vegetada	solo exposto, área urbana, afloramento
39	Soja	a única cultura com classe própria
41	Outras lavouras temporárias	tudo o mais que é lavoura de ciclo curto

A classe 41 é um resto, e não uma cultura. Milho, trigo, feijão, aveia e qualquer outra lavoura temporária caem toda nela, sem distinção. Uma acurácia global alta contra o MapBiomias não implica que o modelo saiba dizer qual lavoura é qual. Implica que ele acerta a fronteira entre soja, o resto das lavouras, mosaico, floresta e solo exposto. É essa fronteira que a concordância mede, e não a identidade da cultura dentro da classe 41.

O que acontece fora do vocabulário. nada visível. Uma área de pastagem pura, de savana, de mangue ou de cana recebe um dos cinco códigos, com confiança, porque o classificador não tem como responder “*nenhuma das anteriores*”. É o modo de falha que a tela não denuncia, e é por isso que o diagnóstico de deslocamento de domínio existe. Ele não corrige a classe errada. Mede se a área desenhada se parece com aquela em que o modelo foi ajustado.

4.2 O caminho `spectral`: 80 atributos por pixel

É o padrão da aplicação. Cada pixel vira um vetor de 80 números, e a figura 4.1 mostra como esses 80 se dividem.

As 14 métricas. são, na ordem em que aparecem no vetor: média, desvio padrão, máximo, mínimo, amplitude, mediana, índice do pico, índice do mínimo, média da estação úmida, média da estação seca, diferença sazonal, variação média entre datas, maior aumento entre datas consecutivas, e maior queda entre datas consecutivas.




Figura 4.1: O vetor de atributos do caminho spectral, lido de `model/feature_names.joblib`. A barra tem 80 posições, da 0 à 79, e está dividida em três blocos contíguos. **Azul, posições 0 a 41:** as 14 métricas temporais, repetidas para cada um dos três índices de vegetação, na ordem NDVI, EVI, SAVI. **Laranja, posições 42 a 57:** quatro estatísticas — média, desvio, máximo e mínimo — para cada uma das quatro bandas de 10 m, na ordem B02, B03, B04, B08. **Verde, posições 58 a 79:** a curva de NDVI sem nenhum resumo, uma posição por data, das 22 datas do protocolo. Os cortes do eixo horizontal marcam as fronteiras entre blocos, em 42 e em 58. A leitura da figura é a proporção: mais de metade do vetor, 64 das 80 posições, descreve o NDVI, primeiro comprimido em métricas e depois repetido cru.

Os três índices sobre os quais elas são calculadas são definidos assim, com ρ a refletância da banda indicada:

$$\text{NDVI} = \frac{\rho_{\text{B08}} - \rho_{\text{B04}}}{\rho_{\text{B08}} + \rho_{\text{B04}}} \quad (4.1)$$

A equação (4.1) é a diferença normalizada entre o infravermelho próximo, B08, e o vermelho, B04. A folha viva reflete forte no infravermelho próximo e absorve no vermelho, então o numerador cresce com a quantidade de folha e o denominador normaliza pelo brilho total da cena. O resultado fica entre -1 e 1 : água e sombra dão valores negativos, solo exposto fica perto de zero, e dossel fechado passa de $0,8$.

$$\text{EVI} = 2,5 \cdot \frac{\rho_{\text{B08}} - \rho_{\text{B04}}}{\rho_{\text{B08}} + 6 \rho_{\text{B04}} - 7,5 \rho_{\text{B02}} + 1} \quad (4.2)$$

A equação (4.2) tem o mesmo numerador do NDVI e um denominador diferente, e é aí que está o ponto. O termo $6 \rho_{\text{B04}}$ e o $-7,5 \rho_{\text{B02}}$ usam o azul para estimar o espalhamento atmosférico e descontá-lo. O $+1$ evita divisão por zero sobre superfície escura, e o fator $2,5$ reescala o resultado para uma faixa comparável à do NDVI. O efeito prático é que o EVI satura mais tarde que o NDVI sobre dossel denso, onde o NDVI já encostou no seu teto e para de distinguir.

$$\text{SAVI} = \frac{\rho_{\text{B08}} - \rho_{\text{B04}}}{\rho_{\text{B08}} + \rho_{\text{B04}} + L} \cdot (1 + L), \quad L = 0,5 \quad (4.3)$$

A equação (4.3) é o NDVI com um termo de solo. O L no denominador amortece a contribuição do brilho do substrato, que é o que faz o NDVI variar sobre lavoura ainda rala mesmo quando a folhagem não mudou. O fator $(1 + L)$ devolve o resultado à escala do NDVI.

Com $L = 0,5$, valor de uso corrente para cobertura intermediária, o SAVI e o NDVI convergem sobre dossel fechado. Divergem sobre solo parcialmente exposto, que é a fase da lavoura em que a distinção entre culturas mais importa.

Estes três índices entram no vetor de atributos calculados no espaço de treino, e não no espaço físico. É a costura do capítulo 3: o NDVI que a aplicação *relata* usa `to_reflectance`, e o bloco de NDVI que o modelo *consome* usa `as_trained`. Os dois não são o mesmo número, e a diferença não é constante ao longo da derivação.

4.3 Os outros dois caminhos

Temporal Transformer. consome a série como sequência, e não como resumo: 22 quadros, seis bandas por quadro, na ordem B02, B03, B04, B8A, B11 e B12. É o único dos três caminhos embarcados que enxerga o infravermelho de ondas curtas, B11 e B12, que o capítulo 2 descreve como já baixado mas não usado pelo classificador padrão. A saída é reduzida por média sobre o tempo antes da decisão.

Prithvi-E0 2.0. usa um modelo de fundação de 300 milhões de parâmetros, congelado, para transformar uma aquisição num vetor de 1024 dimensões, e decide sobre esse vetor com um Random Forest. Toma a cena do meio do período e descarta o resto. O capítulo 2 já qualificou isso: alargar a janela não lhe dá mais dado, muda qual aquisição ele lê. Há dois modos, pixel e patch, que diferem na unidade sobre a qual o embedding é tomado.

O modo Temporal. acumula datas e reporta o que se mantém classificado ao longo do período, em vez de um mapa único. Só existe no spectral: os outros dois produzem o mapa e nada a acumular, e a interface recusa a combinação dizendo isso.

4.4 O que a medição da linha diz sobre a escolha

A linha mediu como diferentes representações do mesmo pixel se saem sobre o MapBiomas real. A figura 4.2 traz o resultado, e ele não é uma ordem única.




Figura 4.2: Acurácia global de cinco representações do mesmo pixel, em dois escopos de validação. Cada painel tem as mesmas cinco barras, na mesma ordem da esquerda para a direita: pheno7, sete métricas fenológicas; a curva de NDVI crua, 22 dimensões; o embedding do Prithvi, 1024 dimensões; e as duas combinações do embedding com cada uma das anteriores. O valor de cada barra está impresso acima dela, e a barra em azul é a que lidera o painel. **Painel da esquerda:** região única com validação cruzada espacial por blocos, $n = 832$, que é a condição mais próxima do uso real da aplicação. **Painel da direita:** regiões misturadas, $n = 4018$. As escalas verticais são independentes, e de propósito: o painel da direita opera entre 0,885 e 0,910, e o da esquerda entre 0,625 e 0,775, de modo que um eixo comum achataria a comparação interna de cada um. O que a figura pede para comparar é a *ordem* dentro de cada painel, não o nível entre painéis. À direita, duas barras aparecem destacadas porque empatam na terceira casa decimal.

Três leituras, e a terceira é a que importa para quem escolhe um modelo na tela.

A curva crua bate o resumo. no painel da esquerda, as 22 posições da curva de NDVI dão 0,702 contra 0,656 das sete métricas fenológicas. Comprimir a série em descritores custa acurácia, e o caminho spectral carrega as duas formas exatamente por isso.

Nem toda dimensão a mais ajuda. o embedding de 1024 dimensões dá 0,719, e somar a ele

as sete métricas leva a 0,724. Somar a curva crua leva a 0,742. O ganho vem de qual informação entra, e não de quantas dimensões.

A ordem inverte entre os escopos. à esquerda, a combinação com a curva crua lidera com 0,742. À direita, ela é a *última*, com 0,893, abaixo do embedding sozinho. Quem lidera à direita é o embedding, puro ou somado às métricas. Os dois empatam em 0,902, e separam 0,000 2 sobre 4 018 amostras. É menos de uma amostra.

A inversão não é ruído, é o efeito da validação. Misturar as regiões põe parte da vizinhança de cada bloco de teste dentro do treino, e a acurácia sobe para todas as representações, de cerca de 0,70 para cerca de 0,89. Um ganho que só aparece nessa condição é um ganho que a validação espacial não confirma. **O painel da esquerda é o que se parece com o uso da aplicação:** um modelo ajustado num lugar, aplicado a uma área que o usuário desenhou em outro.

Entre os dois modelos neurais, a mesma linha mediu o Temporal Transformer contra um perceptron sobre o embedding do Prithvi. Na validação espacial em região única, o perceptron dá 0,737 e o Transformer 0,708. Ter a série crua e o infravermelho de ondas curtas não bastou para o Transformer liderar.

4.5 O que não se pode concluir

Que a figura 4.2 ordena os três botões da tela. ela não ordena. A ablação mede *representações*, e o caminho spectral é um quarto arranjo, de 80 dimensões, que não está nela. O que se pode dizer é que os dois blocos de que ele é feito, as métricas e a curva crua, medem abaixo do embedding do Prithvi nas duas colunas em que aparecem.

Que a melhor combinação está disponível. não está. A que lidera a validação espacial é o embedding somado à curva crua de NDVI, 1 046 dimensões. Ela não é um dos três caminhos embarcados: os artefatos Prithvi em model/ carregam as 1 024 dimensões do embedding e nada mais.

Que acurácia global responde pela sua área. ela é medida sobre o conjunto de validação da linha, no oeste do Paraná. Para a área que você desenhou, o número a olhar é a concordância que a própria execução computa, e não estes. Os capítulos da parte seguinte tratam disso.

Que trocar o modelo troca a legenda. não troca. Os três emitem os mesmos cinco códigos, e um modelo diferente pode mudar qual dos cinco cai em cada pixel. Nenhum deles amplia o vocabulário.

O que o mapa afirma, e em que unidade

A execução terminou. Há um mapa colorido sobre a área, uma lista de classes com percentagem e hectare ao lado, e um valor de confiança. Cada um desses números foi tomado sobre uma amostra específica, e nenhum deles diz o que a leitura imediata sugere.

Este capítulo é sobre a distância entre as duas coisas.

5.1 O que a execução devolve

Tabela 5.1: Os campos numéricos que uma classificação devolve, com a amostra sobre a qual cada um é tomado. A coluna da direita é o que o capítulo detalha adiante.

Campo	O que é	Sobre que amostra
<code>class_stats</code>	por classe: contagem de pixels, percentagem e hectares	os pixels <i>classificados</i> , e não a área desenhada
<code>mean_confidence</code>	média da confiança por pixel	idem, e numa escala que não começa em zero
<code>confidence_floor</code>	o menor valor que a confiança pode assumir	uma constante, $1/K$, com K o número de classes
<code>pixel_size_m</code>	o lado da célula, lido da grade	a execução
<code>n_dates, date_range</code>	quantas cenas entraram e o período que cobrem	a execução
<code>temporal</code>	uma entrada por data, no modo Temporal	a pilha acumulada até aquela data

5.2 As frações de classe, e o denominador

Cada pixel recebe uma das cinco classes, ou o valor -1 quando não pôde ser classificado. A percentagem de cada classe é calculada assim:

$$\text{pct}_c = 100 \cdot \frac{n_c}{\sum_j n_j} \quad (5.1)$$

Na equação (5.1), n_c é a contagem de pixels da classe c , e o denominador soma as contagens de *todas* as classes. O ponto está no que o denominador não inclui: os pixels marcados -1 ficam de fora dos dois lados da fração.

As percentagens somam 100 % do que foi classificado, e não da área que você desenhou. Nuvem, sombra ou ausência de dado tiram parte do polígono, e essa parte não aparece em lugar nenhum da lista. Ela não vira uma classe “*sem dado*”: sai da conta. Uma leitura de 70 % de soja sobre um polígono cuja metade foi descartada descreve 70 % da metade que sobrou.

O número que fecha essa conta é o `n_dates` do capítulo 2, junto da contagem de pixels. A soma de pixels sobre todas as classes, multiplicada pela área da célula, dá a área efetivamente classificada. Comparar essa área com a área do polígono é a verificação, e ela não é feita pela aplicação.

5.3 O hectare é uma contagem de pixels

A área de cada classe sai da contagem, com a célula valendo 100 m^2 :

$$\text{area_ha}_c = n_c \cdot \frac{100}{10^4} \quad (5.2)$$

A equação (5.2) converte pixels em hectares por um fator fixo. O 100 no numerador é a área de uma célula em metros quadrados, vinda de uma grade de 10 m de lado. O 10^4 no denominador é o número de metros quadrados num hectare.

Para o caminho de classificação o 100 está correto: a grade de referência é construída a partir da banda B04, na sua resolução nativa de 10 m.

Duas leituras seguem daí, e as duas importam.

A área não é corrigida por erro de classificação. se o modelo confunde soja com outra lavoura temporária em parte dos pixels, o hectare de soja carrega esse erro inteiro. A conversão é aritmética sobre a contagem, e não uma estimativa de área com incerteza. Estimadores de área que corrigem pela matriz de confusão existem, e a aplicação não os aplica.

O fator está fixado, e o tamanho medido viaja ao lado. o mesmo payload que traz `area_ha` traz `pixel_size_m`, que é lido do *transform* da grade em vez de suposto. Hoje os dois concordam. Se a grade de referência algum dia deixar de ser de 10 m, o hectare não segue o tamanho medido, e nada na saída acusa a divergência. Ao conferir uma área publicada, confira o `pixel_size_m` da execução.

5.4 A confiança não é probabilidade de acerto

O valor de confiança de um pixel é o maior componente do vetor de probabilidades que o classificador devolve:

$$\text{conf} = \max_{c \in \{1..K\}} p_c, \quad \sum_{c=1}^K p_c = 1 \quad (5.3)$$

Na equação (5.3), p_c é a probabilidade atribuída à classe c e K é o número de classes, cinco neste produto. No Random Forest, p_c é a fração de árvores que votou naquela classe; no *Temporal Transformer*, é o componente correspondente do *softmax* da saída. Nos dois casos a confiança mede **concordância interna do modelo**, e não taxa de acerto.

Disso decorre a propriedade que mais engana na leitura. Um vetor de K componentes que soma 1 tem máximo não menor que $1/K$, então a confiança vive em $[1/K, 1]$ e nunca se aproxima de zero. Com cinco classes, o piso é 0,20. A figura 5.1 mostra o efeito na régua.

O deslocamento entre as duas leituras é o que o próprio código registra. Sobre cinco classes, 38 % está a cerca de um quinto do caminho da incerteza máxima até a certeza, e não a um terço. Por isso o payload carrega o `confidence_floor` ao lado da média: sem K , o consumidor não tem como reposicionar o número.

A confiança alta não protege contra a legenda fixa do capítulo 4. Sobre uma área de pastagem, que não está no vocabulário, as árvores podem concordar quase todas em “*mosaico de usos*” e produzir confiança de 0,9. O que esse valor diz é que o modelo não hesitou. Ele não pode dizer que acertou, porque a resposta certa não estava entre as opções.

5.5 O modo Temporal

No modo Temporal, a aplicação não devolve um mapa. Devolve uma sequência: para cada data da janela, ela reclassifica usando a pilha acumulada até ali, das primeiras cenas até aquela, e



Figura 5.1: A escala em que a confiança reportada vive, para as cinco classes deste produto. O eixo horizontal vai de 0 a 1, que é a régua em que o valor aparece na tela. **O bloco cinza à esquerda, de 0 a 0,20, é inalcançável:** nenhum pixel pode receber confiança abaixo de $1/K$, porque o máximo de cinco probabilidades que somam 1 não desce disso. **O bloco azul claro, de 0,20 a 1,00, é a faixa que existe.** Seu extremo esquerdo é incerteza máxima, com as cinco classes empatadas em 0,20 cada, e o direito é certeza do modelo. **A linha laranja marca uma leitura de 0,38,** e a seta abaixo dela mede onde essa leitura cai dentro da faixa que existe: 22 % do caminho entre a incerteza máxima e a certeza. Lida na régua de 0 a 1, a mesma leitura pareceria estar a 38 %.

reporta o resultado.

Cada entrada traz a data, quantas cenas entraram na pilha, a classe dominante e a retenção de soja quando há um raster do MapBiomas para comparar. A leitura é de estabilidade. Uma classe que só aparece com a pilha quase completa depende da série inteira; uma que se firma cedo é decidida pelo começo da estação.

Cada passo do modo Temporal é uma execução completa do classificador sobre a pilha até aquela data, e não um refinamento do passo anterior. O truncamento das 22 datas do capítulo 2 vale em cada passo: os primeiros passos entregam ao modelo um vetor preenchido com zeros nas posições que ainda não têm data.

5.6 O que não se pode concluir

Que as percentagens descrevem o polígono. descrevem os pixels que receberam classe. A fração do polígono que ficou sem dado não aparece na lista.

Que o hectare é uma estimativa de área. é uma contagem convertida. Não carrega correção por erro de classificação nem intervalo.

Que confiança alta indica acerto. indica concordância entre as árvores, ou massa concentrada no *softmax*. Sobre área fora do vocabulário, as duas coisas convivem com resposta errada.

Que 38 % de confiança é pouco mais de um terço da escala. é cerca de um quinto do caminho útil. A escala começa em 0,20, não em zero, e o `confidence_floor` da execução traz esse piso.

Que a classe dominante do modo Temporal converge. nada garante convergência. A sequência pode oscilar entre classes conforme datas entram, e a oscilação é o resultado, não um defeito da leitura.

Parte III

Erro, concordância e transferência

Concordância com o MapBiomas: a matriz e seus intervalos

Quando a área desenhada intersecta o Brasil, a execução compara a classificação com o MapBiomas e reporta uma concordância. É o número que responde à pergunta *onde ele está errando*. Também é o que mais se presta a ser lido além do que mede.

Este capítulo diz o que foi comparado com o quê, sobre quantas observações, e o que ficou fora da conta.

O MapBiomas não é verdade de campo. É um mapa anual, produzido por outro classificador, e em geral defasado da série de datas que a execução leu. O que a aplicação mede é **concordância** entre dois mapas, e um desacordo pode ser erro de qualquer um dos dois. O texto deste livro diz concordância em todo lugar por essa razão.

6.1 A unidade de amostragem é a célula, não o pixel

O MapBiomas é nativo a 30 m e é reamostrado para a grade de 10 m da classificação. Cerca de nove pixels passam então a carregar **uma** observação de rótulo, repetida.

A aplicação agrega a comparação de volta à célula nativa. Cada célula contribui com uma observação: o rótulo de referência que ela carrega, contra a classe majoritária prevista entre os pixels dela. A moda protege a célula que cai sobre uma fronteira de reamostragem, em vez de supor que os nove pixels concordam.

A alternativa seria contar pixel, e ela é atraente porque multiplica a amostra por nove sem nenhum trabalho. A figura 6.1 mostra o que isso faz com o intervalo.




Figura 6.1: O intervalo de confiança de 95 % para a *mesma* acurácia de 75 %, calculado sobre duas contagens do mesmo dado. O eixo horizontal é acurácia em pontos percentuais. **A barra azul, em cima,** é o intervalo sobre 200 células de referência, que é a unidade que a aplicação usa: vai de 68,6 a 80,5, uma largura de 11,9 pontos. **A barra cinza, embaixo,** é o intervalo sobre os 1 800 pixels que essas mesmas 200 células ocupam na grade de 10 m: vai de 73,0 a 77,0, uma largura de 4,0 pontos. O traço branco no meio de cada barra marca a estimativa pontual, idêntica nas duas. A leitura é a razão entre as larguras, 2,98: contar pixel em vez de célula estreita o intervalo por um fator de praticamente três, sem que uma única observação de rótulo nova tenha sido feita.

O fator de três não é coincidência. A meia-largura do intervalo cai com $1/\sqrt{n}$, e multiplicar n por nove a divide por $\sqrt{9}$.

Quando o mapeamento de célula não está disponível, a aplicação devolve *nada* em vez de devolver a conta por pixel. A escolha está registrada no código: uma acurácia com o n errado é pior que nenhuma acurácia, porque continua sendo acreditada.

6.2 A matriz, e as três acurácias

A comparação constrói uma matriz M de cinco por cinco, com as classes previstas nas linhas e as de referência nas colunas. M_{ij} é o número de células que o classificador chamou de i e a referência chama de j . As células certas ficam na diagonal.

Três números saem dela, e respondem a perguntas diferentes.

$$OA = \frac{\sum_i M_{ii}}{n}, \quad PA_c = \frac{M_{cc}}{\sum_i M_{ic}}, \quad UA_c = \frac{M_{cc}}{\sum_j M_{cj}} \quad (6.1)$$

Na equação (6.1), n é o total de células comparadas.

OA, acurácia global. a fração de todas as células em que os dois mapas dizem a mesma coisa. É a soma da diagonal sobre o total. Não distingue classe grande de classe pequena: numa área dominada por uma classe, acertar só ela já entrega uma acurácia global alta.

PA_c, acurácia do produtor. olha uma *coluna*. Das células que a referência chama de c , a fração que o classificador encontrou. O complemento é omissão: o que existia e passou despercebido.

UA_c, acurácia do usuário. olha uma *linha*. Das células que o classificador chamou de c , a fração que a referência confirma. O complemento é comissão: o que foi chamado e não era.

As duas últimas não se movem juntas, e a diferença entre elas é diagnóstico. Um classificador que chama quase tudo de soja não deixa passar quase nada, então a acurácia do produtor para soja fica alta. A do usuário fica baixa, porque a maior parte do que ele chamou de soja não é. O inverso descreve um classificador tímido.

Tabela 6.1: As três acurácias, com a pergunta que cada uma responde e o erro que o complemento mede.

Medida	Lê a matriz por	Responde	O complemento é
Global	a diagonal inteira	em que fração das células os dois mapas concordam	o desacordo total
Do produtor	coluna, por classe	da classe que existe, quanto foi encontrado	omissão
Do usuário	linha, por classe	do que foi chamado assim, quanto de fato é	comissão

6.3 O intervalo é de Wilson, não de Wald

Cada uma das três acurácias vem acompanhada de um intervalo de 95 %. O intervalo é o de Wilson:

$$IC = \frac{\hat{p} + \frac{z^2}{2n}}{1 + \frac{z^2}{n}} \pm \frac{z}{1 + \frac{z^2}{n}} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n} + \frac{z^2}{4n^2}} \quad (6.2)$$

Na equação (6.2), $\hat{p}$ é a proporção observada, n é o número de células e $z = 1,96$ para 95 %. O centro do intervalo não é $\hat{p}$. É $\hat{p}$ puxado na direção de 0,5 por um termo que depende de n , e esse

deslocamento encolhe conforme a amostra cresce. A raiz é o desvio padrão da proporção, com uma correção do mesmo tipo.

Essa forma é escolhida, e a alternativa é o intervalo de Wald, $\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/n}$, que é o que a maior parte das planilhas calcula. O Wald tem dois defeitos nas condições deste produto. Com acurácia perto de 95 % e amostra pequena, ele produz limites acima de 1 ou abaixo de 0, que não são proporções. E ele cobre menos do que promete: um intervalo dito de 95 % contém o valor verdadeiro em menos de 95 % das vezes. Wilson fica dentro do intervalo unitário e mantém a taxa nominal com n pequeno (Brown et al., 2001).

6.4 O que fica fora da conta

Nem toda célula de referência entra na matriz. A área desenhada pode conter água, área urbana, silvicultura ou qualquer outra classe do MapBiomas que não esteja entre as cinco do capítulo 4. Essas células são contadas à parte, no campo `n_outside_legend`, e não entram como erro.

A razão é que contá-las como erro juntaria duas coisas diferentes: *classificado errado* e *fora do vocabulário*. Um classificador que não tem rótulo para água não errou ao não dizer água; ele não foi perguntado.

`n_outside_legend` é a fração da área sobre a qual a avaliação não diz nada. Ela não aparece na acurácia global, nem em nenhuma das acurácias por classe. Uma concordância de 88 % sobre uma área em que um terço das células ficou fora da legenda é 88 % dos dois terços restantes. Confira esse campo antes de ler qualquer um dos outros.

6.5 Kappa não é reportado

A aplicação não devolve o coeficiente kappa, e a ausência é deliberada. O lugar dele é ocupado por duas leituras que o payload já traz. Uma decompõe o desacordo em quantidade e alocação; a outra o distribui pelo espaço, em blocos. Os dois próximos capítulos as desenvolvem.

6.6 O que não se pode concluir

Que a concordância é acurácia. é acordo entre dois mapas, e um deles também erra. Sem verificação de campo, um desacordo não diz de que lado está o erro.

Que a acurácia global descreve as classes. descreve a mistura de classes daquela área. Numa área dominada por uma classe, ela é quase a acurácia daquela classe. As acurácias por classe são o que responde por cada uma.

Que o intervalo cobre o erro do MapBiomas. cobre apenas a variação amostral: quantas células foram comparadas. O erro da própria referência, a defasagem entre o ano dela e a janela da execução, e a diferença de definição entre as duas legendas ficam todos fora dele.

Que uma classe com poucas células tem acurácia medida. o intervalo dela é largo por construção. Uma classe com uma dúzia de células de referência pode reportar 100 % do produtor com um intervalo que desce abaixo de 70 %, e é o intervalo que informa.

Quantidade e alocação: dois erros que não se somam

O capítulo 6 deixou uma conta pela metade. A acurácia global diz em que fração das células os dois mapas concordam, e o complemento dela é o desacordo. Mas o desacordo não é de uma coisa só.

Duas execuções podem errar a mesma fração de células por motivos opostos, e o número único não separa as duas. A aplicação reporta a separação.

7.1 As duas parcelas

Seja M a matriz do capítulo anterior, normalizada pelo total de células, de modo que suas entradas p_{ij} somem 1. Duas somas marginais interessam. $p_{i\cdot}$ é a soma da linha i , a fração que o classificador atribuiu à classe i . $p_{\cdot i}$ é a soma da coluna, a fração que a referência tem dessa classe.

$$Q = \frac{1}{2} \sum_i |p_{i\cdot} - p_{\cdot i}| \quad (7.1)$$

A equação (7.1) é o **desacordo de quantidade**. Para cada classe, ela toma a diferença entre quanto o classificador diz que existe e quanto a referência diz que existe, em módulo, e soma. A metade evita contar duas vezes: todo excesso numa classe é falta em outra, e a soma dos desvios com sinal é sempre zero. Q mede, portanto, apenas o quanto as duas *composições* diferem. Ele não olha onde nada está.

$$A = \sum_i \min(p_{i\cdot} - p_{ii}, p_{\cdot i} - p_{ii}) \quad (7.2)$$

A equação (7.2) é o **desacordo de alocação**. Para cada classe, $p_{i\cdot} - p_{ii}$ é o que o classificador chamou de i e não é. $p_{\cdot i} - p_{ii}$ é o que é i e ele não chamou. O mínimo entre os dois é a parte que pode ser explicada como uma troca: célula que ele deu a outra classe e recebeu de volta na mesma medida. O que sobra além do mínimo é diferença de quantidade, e já foi contado em Q .

As duas parcelas fecham a conta com a concordância:

$$OA + Q + A = 1 \quad (7.3)$$

A equação (7.3) é uma identidade, e não uma aproximação. A figura seguinte a confere em cada caso que desenha, antes de desenhar.

7.2 O mesmo desacordo, dois diagnósticos opostos

A primeira barra é o caso que justifica a decomposição existir. Um classificador que troca soja por outras lavouras temporárias em igual medida **reproduz a composição da referência exatamente**, e erra em todas as células que trocou. Pela composição, os dois mapas não diferem em nada. Pela concordância, 30 % das células discordam. O desacordo de quantidade é o número que vale zero nesse caso, e é por isso que ele não pode ser o único reportado.

Esse não é um caso hipotético dentro do produto. O painel de composição da aplicação compara as duas distribuições marginais, quanto cada mapa tem de cada classe, e essa comparação




Figura 7.1: A decomposição do desacordo em três matrizes sintéticas de exemplo. Cada barra vai de 0 a 1 e representa o total de células de referência, repartido em três segmentos: **cinza, a concordância**, a fração em que os dois mapas dizem a mesma coisa; **laranja, o desacordo de quantidade**; **azul, o desacordo de alocação**. Os três segmentos de cada barra somam 1, que é a identidade da equação (7.3). **Primeira barra, troca simétrica:** as duas classes são trocadas em igual medida, e o desacordo de 0,30 é inteiramente de alocação, com quantidade zero. **Segunda barra, excesso de uma classe:** o classificador chama uma classe demais e a outra de menos, sem troca, e o mesmo desacordo de 0,30 é inteiramente de quantidade. **Terceira barra, mistura:** desacordo de 0,28, repartido em 0,02 de quantidade e 0,25 de alocação. A leitura é a comparação entre as duas primeiras: o desacordo total é idêntico, e o diagnóstico é oposto. As matrizes são construídas para separar os dois regimes e não são execuções do produto.

é o termo de quantidade sozinho. A decomposição foi acrescentada porque o painel estava mostrando metade da conta.

7.3 O que cada parcela pede

As duas parcelas apontam para correções diferentes, e é aí que a separação paga.

Quantidade alta, alocação baixa. os dois mapas discordam sobre quanto existe de cada classe, e concordam sobre onde. Costuma vir de limiar: o classificador é sistematicamente generoso ou tímido com uma classe. Uma comparação de área entre os dois mapas fica inválida; uma comparação de padrão espacial ainda se sustenta.

Alocação alta, quantidade baixa. os dois mapas concordam sobre quanto existe e discordam sobre onde. Aqui a área total por classe pode ser citada com menos risco, e o mapa não serve para dizer qual talhão é qual.

As duas altas. não há leitura segura da execução sobre aquela área. É o caso que o diagnóstico de deslocamento de domínio existe para explicar.

7.4 Kappa não é reportado

O coeficiente kappa ocuparia este lugar em boa parte da literatura de sensoriamento remoto, e a aplicação não o calcula. A omissão é deliberada e está registrada no código. A decomposição em quantidade e alocação vem do trabalho que argumenta contra o kappa (Pontius e Millones, 2011), e é ela que ocupa o lugar dele.

O argumento, em resumo, é que o kappa corrige a concordância por uma concordância *esperada ao acaso* que depende das marginais dos dois mapas. Essa correção mistura na mesma constante coisas que o usuário precisa separar, e o valor resultante é difícil de interpretar sem voltar à matriz. Quantidade e alocação são lidas direto, na mesma unidade da acurácia, e somam com ela.

7.5 O que não se pode concluir

Que a decomposição diz de que lado está o erro. ela parte o desacordo entre dois mapas. Qual dos dois está errado continua sendo pergunta de campo, como o capítulo 6 já colocou.

Que quantidade zero significa mapa certo. significa que as duas composições batem. A primeira barra da figura 7.1 tem quantidade zero e erra três em cada dez células.

Que alocação zero significa que os lugares estão certos. significa que não houve troca compensada. Um classificador que chama uma classe demais em toda parte tem alocação zero e está errado em toda parte onde exagerou.

Que as parcelas se somam a uma taxa de erro. $Q + A$ é o desacordo total, que é $1 - OA$. Não é uma taxa de erro do classificador, pelo motivo do capítulo anterior: parte do desacordo pode ser da referência.

Concordância por blocos: onde a discordância está

Os dois capítulos anteriores deram números que valem para a área inteira. A acurácia global diz quanto, e a decomposição diz de que tipo. Nenhum dos dois diz *onde*.

A diferença importa porque separa dois problemas que pedem trabalho oposto. Um classificador uniformemente mediano tem um problema de modelo. Um que acerta em toda parte menos num canto costuma ter encontrado uma paisagem: uma várzea, a margem de um reservatório, um talhão de uma cultura que a legenda não nomeia.

8.1 A grade

A extensão do raster é dividida numa grade fixa de seis por seis, o que dá 36 blocos. Cada célula de referência é atribuída ao bloco em que o primeiro pixel dela cai, e cada bloco acumula quantas células recebeu e em quantas os dois mapas concordaram.

Seis por lado é escolha de compromisso: dá blocos suficientes para distinguir um canto de um centro, e mantém células suficientes na maioria deles quando a área desenhada é pequena.

Um bloco com menos de 20 células de referência tem a contagem reportada e a percentagem omitida. A razão está no código, e é aritmética: com três células, a percentagem só pode ler 0 %, 33 %, 67 % ou 100 %. Publicá-la ao lado de um bloco de várias centenas convidaria a comparar as duas como se fossem a mesma medida. A contagem viaja de qualquer modo, para que se veja por que a percentagem falta.

8.2 O que é reportado, e por que não é uma média

A saída não é a média dos blocos. É a distribuição deles: quantos blocos foram medidos, a mediana, o intervalo interquartil, o mínimo e o máximo.

A mediana e os quartis, em vez da média e do desvio, porque o conjunto é pequeno e desigual. Trinta e seis blocos, alguns fora da conta pelo piso, e a paisagem sem obrigação de se distribuir simetricamente. Uma média com desvio sobre esse conjunto sugeriria uma simetria que ele não tem.

8.3 O mesmo número global, duas paisagens

A figura foi feita para mostrar que o número global não separa os dois casos. Ao medi-la, ela mostrou mais que isso, e o resto é sobre as estatísticas reportadas.

No painel da direita, o intervalo interquartil é 1,7, praticamente igual ao 1,9 do painel uniforme. **A IQR não vê o canto de baixa concordância.** Quatro blocos em trinta e seis ficam fora dos quartis, então a medida de espalhamento passa por eles sem registrá-los. E a **mediana é maior** no caso com o canto, 90,4 contra 85,0. Lida sozinha, ela ordena a execução da direita acima da outra.

O que captura o canto é o **mínimo**: 40 contra 82. A distância entre a mediana e o mínimo é a leitura, e não cada um deles.

A regra de leitura. compare a mediana com o mínimo, e o mínimo com o piso de células. Uma mediana alta com mínimo muito abaixo dela é o padrão de paisagem localizada. Mediana e




Figura 8.1: Duas grades de blocos com a *mesma* concordância global de 85,0 %. Cada painel é a grade de seis por seis sobre a extensão do raster, com a concordância do bloco impressa dentro dele e codificada em cor pela escala do rodapé, do claro para o escuro conforme a concordância sobe. **Painel da esquerda, uniforme:** todos os blocos entre 82 e 88, mediana 85,0, intervalo interquartil 1,9. **Painel da direita, um canto de baixa concordância:** trinta e dois blocos entre 89 e 93, e quatro blocos no canto inferior esquerdo a 40, visíveis como o bloco pálido na grade. Mediana 90,4, intervalo interquartil 1,7, mínimo 40. As duas grades são construídas para separar os dois regimes e não são execuções do produto; a concordância global das duas é idêntica por construção.

mínimo próximos, com intervalo interquartil estreito, é o padrão de desempenho uniforme, em qualquer nível.

8.4 Não é um teste

O espalhamento entre blocos é descritivo, e a função que o calcula declara isso. Três razões, e nenhuma é removível ajustando o cálculo.

A grade é fixa, não amostrada. os blocos são um recorte regular da extensão do raster, e não uma amostra desenhada para estimar nada.

Os blocos não têm o mesmo tamanho amostral. cada um recebe as células que calharam de cair nele, e o piso de 20 já retira alguns da conta.

Eles não são independentes da paisagem. um talhão, uma várzea ou uma mancha urbana atravessa vários blocos, então blocos vizinhos erram juntos por construção.

Uma avaliação de acurácia com desenho amostral por trás é outra coisa, e Olofsson et al. (2014) é a referência para ela. O que este capítulo descreve não é uma.

8.5 O que não se pode concluir

Que o intervalo interquartil mede a pior região. não mede. A figura 8.1 tem dois casos com IQR quase igual e mínimos que diferem em 42 pontos.

Que uma mediana alta ordena duas execuções. a mediana do caso com o canto de baixa concordância é mais alta que a do caso uniforme. Ela descreve o bloco típico, e a discordância não está no bloco típico.

Que um bloco sem percentagem é um bloco de baixa concordância. é um bloco com menos de 20 células de referência. A contagem dele está no payload, e a ausência da percentagem é

uma recusa de reportar, não um valor baixo.

Que a diferença entre dois blocos é significativa. não há teste aqui, e a comparação entre blocos não tem erro amostral associado. O mesmo vale para a comparação de espalhamento entre duas áreas.

Separabilidade de classes: contraste e assinatura

Os capítulos anteriores mediram o desacordo contra uma referência. Este mede algo anterior: se as bandas observadas *podem* distinguir duas classes, independentemente de qual modelo tenta.

É uma propriedade do dado medido, e não do classificador. Uma distância baixa diz que aquelas bandas, naquela aquisição, não separam aquele par. Não diz que um modelo melhor separaria, e não aponta um reparo.

9.1 De onde saem os números

A execução guarda, por classe prevista e por banda, a média e o desvio padrão da refletância. São sete bandas, de B02 a B12, e o registro só existe para uma classe que tenha ao menos 30 pixels naquela banda.

Duas propriedades desse registro decidem como ele se lê.

É uma aquisição, não a série. a classificação é temporal, com até 22 datas, mas a refletância guardada é a da cena do meio do período. Uma média de sete bandas ao longo de uma estação misturaria estágios fenológicos numa curva que não descreve data nenhuma. A cena usada é nomeada no payload.

É refletância física, com rótulo do outro espaço. o espectro é reportado por `to_reflectance`, com o offset da *baseline* 04.00, porque é uma grandeza física. O classificador que produziu os rótulos consumiu `as_trained`, sem o offset. É a costura do capítulo 3: **os rótulos vêm de um espaço e a refletância reportada para eles vem do outro.**

9.2 A distância, e por que ela satura

Duas classes resumidas por média e desvio numa banda são duas gaussianas, e duas gaussianas têm sobreposição em forma fechada. A distância de Bhattacharyya entre elas é

$$B = \frac{(\mu_1 - \mu_2)^2}{4(\sigma_1^2 + \sigma_2^2)} + \frac{1}{2} \ln \left(\frac{\sigma_1^2 + \sigma_2^2}{2\sigma_1\sigma_2} \right) \quad (9.1)$$

A equação (9.1) tem duas parcelas com papéis distintos. A primeira é a separação entre as médias, dividida pela dispersão conjunta: ela cresce quando as classes se afastam e encolhe quando qualquer uma delas se espalha. A segunda é o desacordo entre as dispersões sozinho, e é por isso que duas classes com a *mesma* média e desvios diferentes não ficam em zero.

B não tem limite superior. Dois pares em $B = 8$ e $B = 14$ ficam distantes um do outro na escala, sendo igualmente separáveis na prática. O painel reporta então a distância de Jeffries-Matusita, que satura:

$$JM = 2(1 - e^{-B}) \quad (9.2)$$

A equação (9.2) leva $B \in [0, \infty)$ para $JM \in [0, 2)$. Acima de cerca de 1,9 o par está separado e mais distância não muda nada que um classificador possa usar.

A leitura convencional é a que o painel desenha em faixas. Abaixo de 1,0 as classes se sobrepõem substancialmente. Entre 1,0 e 1,9 há separação parcial. Acima de 1,9 elas são efetivamente separáveis naquela banda.

9.3 O que a escala exige do dado

Uma distância na escala de 0 a 2 não diz, por si, quanto as classes precisam distar. A figura 9.1 converte a escala em desvios padrão.




Figura 9.1: A distância de Jeffries-Matusita em função de quão longe estão as médias das duas classes, medida em desvios padrão, para duas gaussianas de mesma dispersão. O eixo horizontal é a separação entre as médias; o vertical é a distância, na escala de 0 a 2 em que o painel a mostra. As três faixas horizontais são as faixas de leitura do painel, do mais claro ao mais escuro: **sobreposição substancial** abaixo de 1,0, **separação parcial** entre 1,0 e 1,9, **separável** acima de 1,9. A curva azul é a equação (9.2), calculada pela mesma função que a aplicação executa. As marcas de eixo em 2,35 e 4,90 são as separações necessárias para alcançar as duas fronteiras de faixa. **O ponto laranja** é o melhor valor de banda única que a linha mediu num par de regiões, 0,059, e corresponde a médias distando 0,49 desvio padrão.

Os três números da figura são a leitura toda. Para uma banda sair da sobreposição substancial, as médias das duas classes precisam distar 2,35 desvios. Para chegarem a separável, 4,90. O melhor valor de banda única que a linha mediu corresponde a 0,49 desvio.

9.4 As duas leituras, que não andam juntas

O mesmo cálculo responde a duas perguntas diferentes, e o painel desenha as duas porque elas podem divergir.

Dentro de uma execução, entre duas classes. quanto uma classe se destaca das *outras ao redor dela*, banda a banda. É contraste contra o entorno.

Entre duas execuções, para a mesma classe. quanto a assinatura da própria classe se moveu de uma área para a outra.

Uma cultura cuja refletância é quase a mesma nas duas regiões pode ficar inclassificável na segunda. O que desabou não foi a assinatura dela: foi o contraste contra tudo o mais que está na cena. Reportar só uma das duas leituras torna esse caso ilegível, e é por isso que o painel traz as duas.

9.5 O melhor de sete, e não a média

Quando o painel resume um par de classes num número, ele usa o **máximo** sobre as sete bandas, e não a média.

A razão é a pergunta que se está fazendo. Uma média sobre sete bandas é puxada para baixo pelas seis que não carregam aquela distinção, e reporta como marginal um par que uma banda separa bem. O que interessa é se *alguma* banda separa as duas, e qual.

9.6 O que é recusado, e por quê

Um desvio padrão igual a zero faz a segunda parcela da equação (9.1) divergir, e a implementação recusa o par em vez de regularizar.

A alternativa corrente é somar 10^{-9} a cada variância. Nas condições em que essa correção costuma ser aplicada, um índice contínuo sobre milhares de pixels, o caso degenerado não aparece e o termo só protege o logaritmo. Aqui o desvio chega arredondado a seis casas, sobre no mínimo 30 pixels, então ele *pode* ser exatamente zero. Com 10^{-9} , esse zero viraria uma distância perto de 2, e o par mais separável do painel seria aquele cujo dado foi grosseiro demais para ser medido.

Por isso a saída distingue dois motivos de ausência. A banda *ausente* é a que a classe não reuniu 30 pixels para medir. A *degenerada* é aquela cujo desvio não permite o cálculo. Nos dois casos o painel diz qual foi, em vez de deixar um vazio.

9.7 O que não se pode concluir

Que separabilidade baixa condena a classificação. toda distância aqui é univariada. Um classificador que lê as bandas em conjunto separa classes que nenhuma banda separa sozinha, e a diferença entre as duas coisas não é pequena.

O trabalho de referência dessa medição é o número da figura 9.1. Melhor distância de banda única de 0,059, numa escala que vai a 2, sobre dado em que um Random Forest alcançou macro-F1 de 0,81.

Que a medida vale para a estação. vale para uma aquisição, a do meio do período. Uma cultura pode ser inseparável na data lida e separável seis semanas antes.

Que ela mede a habilidade de um modelo. mede a sobreposição das distribuições observadas. Não é acurácia, não é uma previsão de acurácia, e não indica que caminho de modelo escolher.

Que uma distância alta garante acerto. garante que aquela banda separa as duas distribuições resumidas por média e desvio. Distribuições reais não são gaussianas, e o resumo por dois momentos ignora tudo o que não seja centro e dispersão.

Deslocamento de domínio: o diagnóstico

O capítulo 4 deixou um problema em aberto. A legenda é fechada, então uma área fora do que o modelo aprendeu recebe uma das cinco classes com confiança, e nada na tela denuncia isso.

O diagnóstico de deslocamento de domínio é a resposta parcial. Ele compara duas execuções e mede quanto o dado de uma se afasta do da outra. Não corrige nada, e o capítulo seguinte trata de por que não.

10.1 A impressão digital

Cada classificação guarda uma **impressão digital** compacta do dado que consumiu, e a comparação acontece entre duas dessas, sem reler cena nenhuma.

A impressão contém uma amostra de até 512 pixels do vetor de atributos, com a média e a variância de cada um. Traz também um histograma de NDVI de 32 faixas fixas entre $-0,2$ e $1,0$, e as médias do vermelho e do infravermelho próximo.

Quando o caminho de modelo não produz o vetor de 80 atributos, guarda-se uma impressão só de NDVI. As medidas que dependem do vetor completo degradam, em vez de sumirem.

Padronizada contra o treino, e não contra a execução. os valores comparáveis vêm em desvios padrão do conjunto de *treino*, e não da execução corrente. É o que dá sentido à frase “*este atributo está a três desvios*”. São três desvios do centro daquilo em que a floresta foi ajustada, e não três desvios de si mesma.

10.2 As quatro medidas

Tabela 10.1: As medidas que o diagnóstico reporta, com o que cada uma enxerga e o que ela não alcança.

Medida	O que compara	O que fica fora
KL em NDVI	as duas distribuições de NDVI, faixa a faixa	só NDVI; nada das demais bandas nem da forma temporal
CVA	a distância entre os dois vetores de média, em desvios de treino	tudo o que deixe as médias iguais
MMD com núcleo gaussiano	as duas distribuições inteiras, não só o centro	poder cai com a dimensão; 80 atributos sobre 512 linhas é pouco
Tabela por atributo	qual atributo moveu, e quanto, em desvios de treino	a importância que a pondera ordena, não quantifica

KL. é calculada nos dois sentidos e reportada simetrizada, como a média de $KL(A||B)$ e $KL(B||A)$, com as duas direções também disponíveis. A divergência não é simétrica por natureza, e reportar uma direção só faria a leitura depender de qual execução foi chamada de primeira.

CVA. é a norma da diferença entre os dois vetores de média. Como as unidades são desvios de treino, o número se lê direto. Um CVA de 3 diz que o centro da execução B está a três desvios do centro de A, na régua do treino.

A direção dessa mudança também é reportada, como o ângulo do vetor no plano vermelho–infravermelho. Sazonalidade e desmatamento puxam para lados diferentes desse plano.

10.3 Por que o núcleo do MMD é gaussiano

O MMD compara duas distribuições inteiras através de um núcleo, e a escolha do núcleo decide o que ele consegue ver.

Com núcleo linear, a estatística se reduz a $\|\mu_A - \mu_B\|$, que é a magnitude do vetor de mudança calculada de outro jeito. Em execuções reais as duas concordaram até o último dígito reportado, então o relatório carregava uma medida sob dois nomes.

Pior que a redundância é a cegueira. A figura 10.1 a mede.




Figura 10.1: Duas comparações entre amostras, com as duas medidas calculadas pelas funções do próprio sidecar. Cada painel mostra duas nuvens de pontos, a execução A em azul e a execução B em laranja, e traz abaixo a magnitude do vetor de mudança e o MMD ao quadrado. **Painel da esquerda:** as duas nuvens têm a mesma média e dispersões diferentes, com a de B mais que o dobro da de A. A magnitude do vetor de mudança é 0,000 0, e o MMD ao quadrado é 0,176: a primeira medida não vê nenhuma diferença, e a segunda vê. **Painel da direita:** as nuvens têm a mesma dispersão e médias deslocadas. A magnitude é 2,069 0 e o MMD ao quadrado é 0,405, e as duas medidas registram a diferença. As amostras são sintéticas e bidimensionais para caberem na página; a impressão digital de uma execução tem 80 dimensões.

O painel da esquerda é a forma do deslocamento condicional: a *mesma* classe emitindo um espectro diferente, com centro parecido. Uma medida que olha só o centro dá zero para ele. É a razão de o núcleo ser gaussiano, que é característico: o MMD só vale zero quando as duas distribuições são iguais (Gretton et al., 2012).

O estimador do MMD é não enviesado, e por isso pode dar levemente negativo quando as duas amostras vêm da mesma distribuição. O valor negativo é reportado como está, sem truncar em zero. Um negativo pequeno é o sinal de que as duas são indistinguíveis naquele tamanho de amostra, e truncá-lo apagaria essa informação.

10.4 A tabela por atributo

As três medidas anteriores dizem *que* os domínios diferem. A tabela por atributo diz *onde*.

Ela lista o deslocamento de cada atributo entre as duas execuções, em desvios de treino. Ao lado vem uma coluna que multiplica esse deslocamento pela importância que a floresta atribui ao atributo. Um movimento grande num atributo em que o modelo quase não separa não é a mesma coisa que um movimento pequeno num de que ele depende.

A importância usada é a de impureza, que é enviesada a favor de atributos com muitos valores distintos (Strobl et al., 2007). Ela serve para **ordenar**, e não para quantificar. As duas colunas são reportadas lado a lado, e nenhuma é apresentada como a resposta sozinha.

Ao lado disso, a projeção em duas dimensões dos dois conjuntos de amostras permite ver a separação em vez de lê-la. É descritiva, e a posição de um ponto nela não tem unidade.

10.5 O que não se pode concluir

Que um MMD pequeno significa ausência de deslocamento. o poder da estatística cai com a dimensão (Ramdas et al., 2015), e 80 atributos contra 512 linhas não é o regime em que um valor pequeno autoriza essa conclusão. O próprio módulo registra isso.

Que o diagnóstico corrige alguma coisa. ele mede. A adaptação de domínio está declarada fora do escopo do módulo, e o capítulo seguinte diz por quê.

Que KL baixa significa domínios próximos. a KL aqui é calculada sobre o NDVI e mais nada. Duas áreas podem ter a mesma distribuição de NDVI e diferir em todas as outras bandas, ou na forma da curva ao longo da estação.

Que um atributo no topo da tabela é a causa. a tabela ordena deslocamentos. Atributos correlacionados se movem juntos, e a ordenação por importância de impureza carrega o viés da nota acima.

Que a comparação vale contra o conjunto de treino. ela compara duas *execuções*. A padronização é feita em desvios de treino, o que torna os números legíveis nessa régua, mas nenhuma das duas execuções é o conjunto de treino.

Deslocamento de domínio: o que ele não corrige

O capítulo anterior descreveu um diagnóstico que mede e não conserta. A adaptação de domínio está declarada fora do escopo do módulo, e isso costuma soar como trabalho pendente.

Não é. A linha testou a adaptação, e o resultado dela é a razão de a aplicação não a embarcar.

11.1 Seis correções, nenhuma funcionou

O problema tem uma restrição que não é simplificação: há rótulo abundante na região de origem e nenhum na de destino, então ajuste fino está excluído por construção. As correções precisam ser cegas ao rótulo do destino.

A linha testou seis famílias sobre um par real, Iowa contra o oeste do Paraná. Mesmo sensor, mesma cultura, hemisférios opostos. Vão do calendário puro à rede que recebe clima e aprende o que fazer com ele.

Nenhuma funcionou. O gap de transferência fica em torno de 40 pontos percentuais em todas, e o melhor método bate o baseline por 0,5 ponto, dentro do desvio entre sementes. O teto no domínio de origem é 0,996, então não se trata de um classificador fraco.

11.2 A correção física ganha num lugar e perde no outro

Uma das seis correções tem fundamento físico, e não estatístico. Ela reindexa a série temporal em graus-dia acumulados, em vez de dias de calendário, para comparar as duas regiões em tempo de desenvolvimento e não em tempo de relógio.

A figura 11.1 mostra o que ela fez nos dois experimentos da linha.

A inversão pede explicação, e ela não é que um dos dois experimentos esteja errado.

No sintético, a fase térmica foi plantada. o gerador construiu o deslocamento com data de plantio e acúmulo térmico entre os mecanismos. Uma correção de fase resolve, por definição, um deslocamento cuja causa é a fase.

No real, o par atravessa o equador. a literatura que reporta ganho com tempo térmico, de 21,2 pontos, mede um par temperado contra temperado, no mesmo hemisfério, sem inversão de estação. Entre Iowa e o Paraná a janela de sobreposição térmica cobre só parte do ciclo de cada lado.

A conclusão que sobrevive aos dois não é “*graus-dia funciona*” nem “*graus-dia não funciona*”. É que reindexar em tempo térmico corrige o deslocamento *quando ele é de fase térmica*, e não corrige quando o gap é de outra natureza. Aplicar a correção exige antes um diagnóstico que diga em qual dos dois casos se está, e esse diagnóstico não existe.

11.3 Duas armadilhas medidas no caminho

As correções não comutam. no experimento sintético, a normalização de forma aplicada sozinha custa 12,3 pontos, e aplicada sobre o registro por marcos rende 14,3. A ordem é alinhar o tempo primeiro e a radiometria depois. Uma ablação que reporte correções isoladas mede outra coisa.




Figura 11.1: O gap de transferência de cada família de correção, em dois experimentos. Barra mais curta é melhor: o gap é quanto o desempenho no destino fica abaixo do teto na origem, em pontos percentuais. **Painel da esquerda, experimento sintético:** o deslocamento entre as duas regiões foi construído peça por peça, com plantio, temperatura, fotoperíodo, solo e nuvem como mecanismos nomeados. O gap sem correção é 52,8, e a reindexação em graus-dia o leva a 8,4, o menor de todos. **Painel da direita, par real de Iowa para o oeste do Paraná:** todas as famílias ficam entre 39,7 e 54,3, e o baseline de calendário puro está em 40,2. **As barras em laranja são as correções de tempo térmico**, as mesmas nos dois painéis. À esquerda elas ocupam as duas primeiras posições; à direita, a reindexação em graus-dia dá 43,0, pior que não corrigir nada, e a versão fototérmica dá 54,3, a pior de todas.

Nenhum indicador sem rótulo escolheu o método. a linha testou três candidatos a substituto do rótulo para ordenar os métodos, e todos falharam. A entropia da predição correlaciona com o desempenho real em +0,29, com o *sinal invertido*: o modelo é mais confiante justamente onde erra mais.

11.4 O que reinterpretoou todo o resto

Os estudos acima compararam contra o MapBiomas no destino, e o capítulo 6 já registrou que o MapBiomas é um mapa produzido por outro classificador. Um teto baixo no destino podia ser sobreposição física entre as classes **ou** erro da referência, e nenhum daqueles desenhos separava as duas.

Um estudo posterior separou. Ele troca o par por dois domínios que têm rótulo de declaração do produtor nos dois lados, mantendo o contraste climático.

■ O teto no destino é 0,99, e não 0,65. Com o mesmo NDVI e o mesmo classificador, o que antes parecia limite físico de separabilidade era, em boa parte, **erro da referência**.

Isso reinterpreta retroativamente os números deste capítulo: uma fração grande dos cerca de 34 pontos chamados de irredutíveis era erro do MapBiomas, e não sobreposição entre soja e pastagem.

Para quem usa a aplicação, a consequência junta este capítulo com o 6. Suponha que o diagnóstico de domínio acuse distância e a concordância caia. Há duas causas possíveis, e o produto não as separa. A área pode estar fora do que o modelo aprendeu, ou a referência contra a qual ela é medida pode estar errada ali.

11.5 O que não se pode concluir

Que adaptação de domínio não funciona. não funcionou naquele par, com aquelas seis famílias, contra aquela referência. A última cláusula é a que o próprio material derrubou depois.

Que o gap de 40 pontos é físico. boa parte dele era erro de rótulo da referência, medido por contraste com um par que tinha rótulo de declaração.

Que o tempo térmico deve ser evitado. ele recupera 44,8 pontos quando o deslocamento é de fase térmica. O que falta é o diagnóstico que diga quando é esse o caso.

Que a confiança do modelo ajuda a escolher. a correlação medida entre entropia da predição e desempenho real tem sinal invertido. Nesse par, ela levaria à escolha errada.

Parte IV

Água e terreno

Água superficial por índice espectral

A água superficial é o produto que menos herda das limitações dos capítulos anteriores. Não há modelo treinado, então não há legenda fixa e não há domínio de onde sair.

O que existe são três índices publicados, um limiar por data, e duas decisões de implementação que decidem se o resultado mede água ou mede ausência de observação.

Este produto não tem estudo dedicado na linha *TERRA-Research*. Os três índices são publicados e citados abaixo, e a implementação foi portada de uma análise anterior do próprio projeto. O capítulo 1 coloca isso na tabela de validação: o que sustenta o número aqui é a fonte original de cada índice, e não uma medição própria.

12.1 Os três índices

Todos partem do verde, B03, e diferem no que colocam do outro lado da diferença.

$$NDWI = \frac{\rho_{B03} - \rho_{B8A}}{\rho_{B03} + \rho_{B8A}} \quad (12.1)$$

A equação (12.1) contrasta o verde com o infravermelho próximo (McFeeters, 1996). Água absorve fortemente no infravermelho próximo e reflete relativamente bem no verde, então a diferença fica positiva sobre água e negativa sobre vegetação, que faz o contrário.

$$MNDWI = \frac{\rho_{B03} - \rho_{B11}}{\rho_{B03} + \rho_{B11}} \quad (12.2)$$

A equação (12.2) troca o infravermelho próximo pelo de ondas curtas (Xu, 2006). Superfície construída também é escura no infravermelho próximo, e o NDWI a confunde com água. No infravermelho de ondas curtas a água absorve ainda mais e o concreto não. É o índice que a aplicação usa por padrão.

$$AWEI = 4(\rho_{B03} - \rho_{B11}) - (0,25 \rho_{B8A} + 2,75 \rho_{B12}) \quad (12.3)$$

A equação (12.3) abandona a forma normalizada e usa coeficientes ajustados (Feyisa et al., 2014). O primeiro termo é o contraste do MNDWI multiplicado por quatro; o segundo desconta refletância nos dois infravermelhos, que é onde solo escuro e sombra ainda respondem. O resultado não é limitado entre -1 e 1.

A variante implementada é a **AWEI_{nsh}**, a de *não sombra*. O trabalho original propõe duas, e a outra é a que trata sombra explicitamente. Nenhum dos três índices deste capítulo distingue água de sombra de nuvem ou de encosta.

B8A e não B08. onde a fórmula original pede infravermelho próximo, a implementação usa a banda estreita B8A, de 20 m, e não a B08 de 10 m. A escolha vem da análise que originou o código, cuja pilha foi montada sobre o conjunto de bandas do Prithvi. Usar B08 mudaria o NDWI e o AWEI e não reproduziria a série de referência.

12.2 O limiar por data

O corte de literatura é zero para os três índices. A aplicação também estima um limiar por data pelo método de Otsu, que escolhe o corte que maximiza a variância entre as duas classes do histograma.

Sobre esse limiar há um detalhe que precisa ser lido junto do resultado.

O limiar de Otsu é preso a um intervalo empírico entre $-0,2$ e $0,4$, para que ele não vá para um corte degenerado quando a área é quase toda terra. Esse limite inferior é alcançado com frequência. Nas propriedades de referência ele satura em 12 de 22 datas, 9 de 21 e 20 de 20. Quando isso acontece, o valor reportado é o *limite*, e não uma estimativa, e a saída o marca como tal.

12.3 As duas correções que decidem o produto

A implementação diverge deliberadamente da análise de onde veio, em dois pontos. Os dois tratam da mesma confusão: ausência de observação lida como ausência de água, ou como presença dela.

Validade por data, e não pela união das datas

O protótipo construiu uma máscara de validade única, pela união das datas. Um pixel ausente numa data continuava contando naquela data. As bandas dele valem zero, então todo índice de razão avalia exatamente $(0 - 0)/(0 + 0 + \varepsilon) = 0,0$. A comparação é índice $\geq 0,0$, então **o pixel entra como água**.




Figura 12.1: O que o protótipo contava como água, em três propriedades de referência. Cada barra é o total de pares pixel-data que ele reportou como água ao limiar fixo, e o número à esquerda dá esse total. **A parte cinza é a fração desses pares em que o pixel não tinha observação naquela data** e entrou como água por aritmética, com as bandas em zero. **A parte azul, à direita, é o que restava de água de fato**, com a contagem impressa ao lado. Nas três propriedades: 906 de 909, 980 de 985 e 1171 de 1171. Na terceira, a barra azul não existe: nenhum dos pares reportados era água.

Carregar esse comportamento teria produzido um produto de água que mede observação faltante. A validade passa a ser avaliada por data, a partir das bandas que o índice selecionado consome. A máscara final é intersectada com ela de novo, de modo que um pixel não observado nunca possa ser reportado como água.

Denominador por pixel, e não pelo total de datas

A segunda correção é da mesma família. O mapa de ocorrência é a fração das datas em que um pixel foi água, e o protótipo dividia pelo número total de datas da janela. Isso mistura seco com

ausente. Um pixel visto em quatro datas e molhado em uma lê 0,25 pelo denominador correto, e bem menos que isso se o denominador for a janela inteira.

O denominador é agora por pixel. Um pixel nunca observado devolve ausência de valor, e não zero.

12.4 Persistente e efêmero

Sobre a ocorrência, a aplicação separa três faixas:

Tabela 12.1: As faixas de ocorrência, com a fração das datas observadas em que o pixel apareceu como água.

Faixa	Ocorrência	Como ler
Persistente	acima de 70 %	água na maior parte das datas em que o pixel foi visto
Efêmero	de 15 % a 70 %	água em parte das datas; margem de reservatório, várzea, lâmina de irrigação
Abaixo da faixa	menos de 15 %	não reportado como água

As duas primeiras faixas são reportadas separadas e nunca somadas. Somá-las produziria uma área de água que não existe em data nenhuma: a extensão máxima alcançada em algum momento da janela, apresentada como se fosse um espelho.

12.5 O que não se pode concluir

Que a máscara distingue água de sombra. não distingue. A variante do AWEI implementada é a de não sombra, e nenhum dos três índices trata sombra de nuvem ou de encosta.

Que a soma de persistente e efêmero é a área do corpo d'água. é a união de duas coisas medidas em datas diferentes. A área de um espelho numa data é a máscara daquela data.

Que o limiar reportado é sempre uma estimativa. quando ele bate no limite empírico, o valor é o limite. A saída marca isso, e nas propriedades de referência isso aconteceu na maioria das datas em dois dos três casos.

Que a ocorrência é comparável entre pixels. o denominador é por pixel, e dois pixels com ocorrência de 50 % podem ter sido vistos em vinte datas e em duas. A contagem de observações acompanha o valor.

Que o produto herda as limitações do classificador. não herda. Não há modelo treinado aqui, então não há legenda fixa nem domínio de treino, e os capítulos 4 e 10 não se aplicam a ele.

A cadeia de terreno: da grade ao HAND

A envoltória de cheia não lê o Sentinel-2. Ela lê modelos de elevação e roda sobre eles uma cadeia clássica de análise de terreno. O que sai dela é uma altura: quanto cada célula está acima da drenagem para a qual escoar.

Este capítulo descreve essa cadeia e as decisões dentro dela que mudam o resultado. O produto que sai dela é o assunto do capítulo seguinte.

13.1 A cadeia, passo a passo

O encadeamento é o de Nobre et al. (2011), em cinco passos. Preencher as depressões, dirigir o fluxo, acumulá-lo, extrair a drenagem por um limiar de área, e medir a altura de cada célula acima da drenagem para a qual escoar.

Preencher as depressões. usa Priority-Flood com um ϵ (Barnes et al., 2014). O resultado é um modelo sem mínimo interior e sem platô: toda célula fica ao menos ϵ acima daquela por onde a água a deixou. O ϵ não é cosmético. Sem ele, um lago preenchido vira um platô, e sobre um platô não existe direção de fluxo definida.

Dirigir o fluxo. cada célula aponta para o vizinho de maior descida entre os oito, e uma célula sem vizinho mais baixo recebe -1 : ali a água sai do domínio. Depois do preenchimento isso só acontece na borda, e é essa propriedade que torna o grafo acíclico.

Acumular. conta quantas células escoam através de cada uma, ela inclusa, seguindo a ordem topológica do grafo.

Extrair a drenagem. é uma célula toda aquela cuja área contribuinte ultrapassa um limiar. O padrão é $0,5 \text{ km}^2$, que a 30 m de lado equivale a cerca de 555 células.

Medir a altura. percorre a ordem topológica de trás para frente, de jusante para montante, de modo que a elevação de drenagem do receptor já esteja resolvida quando a célula é visitada.

■ A altura é medida contra o **DEM original**, e não contra o preenchido. Dentro de uma depressão preenchida isso produz HAND negativo, e o valor é informação: a célula está *abaixo* da drenagem dela. Quem consome decide se corta em zero, e o módulo não corta.

13.2 Por que a cadeia é reimplementada

Existem bibliotecas prontas para isso, e a aplicação não as usa. São duas razões, e as duas são declaradas no código.

Dependência compilada. as bibliotecas usuais trazem extensões que precisam ser construídas. A distribuição do TERRA constrói o próprio interpretador, e um pacote que falhe ao compilar ali falha na instalação, numa máquina sem compilador e sem ninguém para ler o erro.

O limiar de drenagem. é um parâmetro livre que quase nenhum estudo de cheia reporta, e este produto mede o efeito dele. Uma medição de um parâmetro enterrado dentro de uma dependência é a medição de algo que o leitor não vê.

O custo dessa escolha está medido. Uma grade de 900×900 , que a 30 m cobre um quadrado de 27 km de lado, leva $3,5 \text{ s}$ na cadeia inteira. São cerca de $4,3 \mu\text{s}$ por célula.

13.3 Quatro produtos, uma grade

A envoltória compara produtos de elevação, então cada um deles precisa ser lido sobre o mesmo chão, no mesmo momento e pelo mesmo caminho. Do contrário, uma diferença entre dois produtos é uma diferença entre dois modos de leitura.

São quatro: cop-dem-glo-30, nasadem e alos-dem, todos a 30 m, e cop-dem-glo-90 a 90 m. Todos vêm do mesmo catálogo que a aplicação já lê para as imagens.

13.4 Por que a janela é maior que a área

O HAND de uma célula depende da área que escoar para ela, e essa área pode vir de fora da região desenhada. A leitura é feita por isso numa janela de 2 a 5 km além da área, com todos os *tiles* interceptados mesclados.

A busca no catálogo é feita pela **janela ampliada**, e não pela área. Um *tile* que só toque o anel de margem nunca seria devolvido por uma busca pela área, e a mescla ficaria com um buraco exatamente onde entra a água.

Medido sobre o Copernicus GLO-30 do baixo Taquari, cortar o modelo na borda de uma área de 8 km de lado custa 0,4 ponto percentual de extensão. Entre 2 e 4 km custa de 1,9 a 2,4 pontos. O efeito existe, e é modesto para área de vários quilômetros.

Abaixo de cerca de 1,5 km de lado ele **inverte de sinal**: o recorte passa a reportar *mais* mancha que a leitura correta, 21,0 % contra 14,5 %.

A causa é aritmética. A célula desse modelo mede 827 m², então o limiar de drenagem de 0,5 km² equivale a 605 células. Uma área de 1 km de lado contém 1369 células ao todo, e a área contribuinte máxima que qualquer célula dela pode acumular é 1,13 km². Só 16 células cruzam o limiar, todas na saída do recorte. Sem rede de drenagem interna, quase toda célula mede altura contra a borda por onde a água sai, que está perto e baixa: HAND desaba e a mancha infla.

A regra que sai disso. numa área cujo lado é da ordem da raiz do limiar de drenagem, a margem não é refinamento. O valor reportado sem ela não é uma estimativa imprecisa da mancha: é outra quantidade.

13.5 O que a cadeia produz

13.6 O limiar de drenagem decide o resultado

O parágrafo acima nomeou o limiar de drenagem como a razão de a cadeia ser reimplementada. A tabela 13.1 mede por quê, no mesmo terreno da figura.

Tabela 13.1: O efeito do limiar de área de drenagem sobre a extensão reportada, no baixo Taquari, com a cadeia do sidecar. O limiar de HAND é o mesmo em todas as linhas; o que muda é quantas células contam como drenagem.

Limiar	Em células	Células de drenagem	Extensão a 1 m	Extensão a 2 m
0,1 km ²	121	5,26 %	14,2 %	18,8 %
0,5 km ²	605	2,49 %	10,2 %	13,5 %
2 km ²	2 419	1,32 %	7,6 %	10,0 %
10 km ²	12 096	0,63 %	4,9 %	6,3 %
50 km ²	60 480	0,36 %	3,3 %	4,2 %




Figura 13.1: As três camadas da cadeia sobre o mesmo lugar real: o baixo vale do Taquari, no Rio Grande do Sul, num quadrado de cerca de 23 km de lado que contém Lajeado, Estrela e Cruzeiro do Sul. **Painel da esquerda, elevação:** o Copernicus GLO-30 como a cadeia o recebe, do escuro (baixo) ao claro (alto), com o rio meandrando no fundo do vale e as encostas em volta. **Painel do meio, HAND:** a altura de cada célula acima da drenagem para a qual ela escoar, em metros, saturada em 20. O azul escuro marca o que está próximo da drenagem, e a rede dendrítica que aparece é a própria estrutura de vales, e não o rio desenhado. **Painel da direita, a extensão até 2 m de HAND:** as células abaixo desse limiar, em azul, sobre o terreno mais alto em cinza. São 13,8 % da área, e a forma delas é o fundo de vale de toda a rede, não apenas a calha principal. A cadeia é a do sidecar, com o limiar de drenagem no padrão de 0,5 km².

A linha em negrito é o padrão da aplicação. Entre a primeira linha e a última, a extensão a 2 m vai de 18,8 % a 4,2 %. São **um fator de quatro e meio**, sem que o terreno ou o limiar de HAND tenham mudado.

Duas manchas de HAND só são comparáveis se tiverem sido produzidas com o mesmo limiar de drenagem. Um número de extensão sem esse parâmetro declarado não é verificável. É por isso que a aplicação o mantém fixo, em 0,5 km², e o declara no resultado.

A cadeia solar não faz isso. O capítulo 2 já registrou: `solar.fetch_dem` lê o primeiro *tile* que o catálogo devolve, sem mesclagem. Os *tiles* Copernicus são de um grau, então uma área que atravessa uma borda recebe um modelo que cobre parte dela. Para declividade e orientação isso degrada em manchas, e é limitação dos mapas de irradiação sobre terreno e de sítio, não desta cadeia.

13.7 O que não se pode concluir

Que uma mancha de HAND é uma mancha de cheia. HAND é altura acima da drenagem. Não há chuva, não há vazão, não há roteamento e não há tempo. Um limiar de HAND delimita o terreno que estaria abaixo de uma lâmina daquela altura, e não a lâmina que um evento produziria.

Que o limiar de área de drenagem é neutro. ele decide quais células são drenagem, e portanto contra o que todas as outras medem altura. O padrão de 0,5 km² é a escolha da referência, e o produto o mantém fixo e declarado em vez de varrê-lo.

Que HAND negativo é erro. é uma célula abaixo da drenagem dela, dentro de uma depressão que o preenchimento fechou. O módulo não corta em zero.

Que a margem resolve a truncagem. ela a empurra para longe. A área contribuinte de uma célula de várzea é ilimitada em princípio, e o que entra de além da margem continua faltando.

Que os números medidos valem para outra bacia. a figura 13.1 e a tabela 13.1 medem uma planície de inundação específica. O que transfere é a forma do argumento e a conta de células, e não os pontos percentuais.

A envoltória: o raster de concordância

O capítulo anterior terminou numa mancha: as células abaixo de um limiar de HAND. Falta a pergunta que decide se ela pode ser usada.

Uma mancha de HAND sai de um modelo de elevação, e há vários deles sobre o mesmo chão. Se dois produtos discordarem sobre onde está a drenagem, discordarão sobre a mancha. O produto do TERRA não é a mancha de um modelo: é a mancha *com a divergência entre modelos ao lado*.

14.1 O raster de concordância

Quatro produtos de elevação são lidos sobre a mesma grade, e a cadeia do capítulo 13 roda uma vez para cada um. No limiar de referência de 1 m, cada um produz a sua máscara.

O raster de concordância conta, célula a célula, quantos deles chamam aquela célula de inundada. O número vai de 0 a 4, e a leitura é direta.

Onde a contagem é **0 ou 4**, os produtos não discordam: quem decidiu foi o terreno. Onde ela fica **entre 1 e 3**, quem decidiu foi a escolha do produto de elevação.

Uma máscara única com uma acurácia ao lado não mostra isso. Ela dá uma forma, e a forma muda com o produto sem que nada na tela avise.

Nessa execução, dos 20,5 km² que algum produto chama de inundados dentro da área, 4,9 km² são unânimes e 15,6 km² são contestados. **São 76,1 % da extensão molhada decididos pela escolha do modelo de elevação**, e não pelo terreno.

A contagem zero não é um nível de concordância. Uma célula que nenhum produto chama de inundada não carrega medida de acordo entre eles: ela é o resto seco da área, e é reportada como tal. A fração contestada é tomada sobre a extensão molhada, e não sobre a área inteira, porque é dessa extensão que ela é uma parcela.

14.2 IoU, que é o CSI da literatura

A concordância entre dois produtos é medida pelo índice de Jaccard entre as duas máscaras:

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (14.1)$$

Na equação (14.1), A e B são os conjuntos de células que cada produto chama de inundadas. Para máscaras binárias esse valor é numericamente o *Critical Success Index* da literatura de inundação, $TP/(TP + FP + FN)$. A mesma coluna se lê como CSI, sem conversão.

Essa equivalência abre uma leitura sobre o alcance do método.

Quando um método HAND é avaliado contra uma mancha observada, o CSI que ele alcança é comparado com o de outros métodos. A linha da figura 14.1 em 1 m é **o CSI que o baseline tem contra ele mesmo**, medido entre produtos de elevação do mesmo método. É um teto para o que qualquer método HAND pode alcançar naquela área com aqueles dados.




Figura 14.1: Uma execução da envoltória sobre um recorte de cerca de 8 km de lado no baixo Taquari, entre Lajeado e Estrela. **Painel da esquerda, o raster de concordância no limiar de referência de 1 m:** cada célula recebe a cor da contagem de produtos que a chamam inundada, do cinza (nenhum dos quatro) ao azul escuro (todos os quatro), com os três tons de laranja entre eles. O retângulo tracejado é a área desenhada, e o que está fora dele é a margem que a cadeia lê e não reporta. A leitura é a forma: **a calha principal aparece em azul, contínua**, e em volta dela há uma franja larga de laranja. O terreno decide o canal; a franja é decidida pela escolha do modelo. **Painel da direita, a concordância entre pares:** para cada limiar de HAND, a barra vai do menor ao maior IoU entre os seis pares de produtos. Em 1 m os pares ficam entre 0,45 e 0,52; em 20 m, entre 0,83 e 0,87. Quanto mais apertado o limiar, menos os produtos concordam.

14.3 A discordância não é de borda

Produtos podem discordar por efeito de borda: recorte, reamostragem, truncagem da drenagem. O produto testa essa hipótese em vez de a descartar.

Ao lado de cada IoU vem um **IoU do inset**, calculado sobre a área encolhida por um anel de 1 km cortado da própria borda dela. Se a discordância fosse de borda, o valor do inset subiria.

Na execução da figura ele não sobe. Em 1 m, a faixa sobre a área é de 0,45 a 0,52, e sobre o inset é de 0,42 a 0,52.

O anel tem um teto. numa área pequena, um anel de 1 km consumiria o polígono inteiro. Ele é limitado a metade do lado menor da área, e o valor efetivamente usado é reportado junto do IoU do inset. Sem isso, um inset de 1 km seria comparado com um de 200 m.

14.4 O que a saída declara junto dos números

Três parâmetros acompanham a medição, e sem eles nenhum dos números é comparável.

O limiar de drenagem. fixo em $0,5 \text{ km}^2$, pelo motivo que a tabela 13.1 mede: ele move a extensão por um fator de quatro e meio.

O limiar de referência do raster. 1 m. É onde o estudo que originou o produto reporta a maior discordância entre modelos. Uma envoltória desenhada num limiar mais alto reporta uma discordância menor, como o painel da direita da figura mostra.

A área contra a janela. toda contagem, área e fração do payload é tomada dentro do polígono desenhado. A janela sobre a qual a cadeia rodou é maior, e as duas aparecem lado a lado no resultado. Resumir a janela em vez do polígono inflaria cada figura de área.

I O conjunto de modelos do TERRA não é o do estudo que originou o produto. Aquele usou quatro produtos obtidos com credencial em outro catálogo, e este lê o catálogo que a aplicação já lê, sem credencial. Esse catálogo não tem SRTMGL1, e alos-dem ocupa o lugar dele. **A faixa publicada pelo estudo não é uma previsão da faixa que o TERRA mede**, e o resultado carrega esse qualificador no próprio payload.

14.5 O que não se pode concluir

Que a franja contestada é erro. ela é o intervalo dentro do qual os modelos disponíveis não decidem. Nenhum dos quatro é verdade de campo, e a célula contestada pode estar inundada ou seca.

Que IoU alto significa mancha correta. significa que os produtos concordam entre si. Quatro modelos que herdaram o mesmo viés concordam sem que nenhum esteja certo.

Que a fração contestada de uma área vale para outra. ela depende do relevo, do limiar e do conjunto de produtos. Na execução da figura são 76,1 % da extensão molhada; noutro relevo será outro número.

Que a envoltória cobre a incerteza do produto. cobre uma fonte dela, a escolha do modelo de elevação. O limiar de drenagem, o limiar de HAND e a ausência de chuva e de vazão continuam fora, e os três já apareceram no capítulo 13.

Parte V

Energia

Recurso solar no ponto

Os produtos anteriores dependem de cena. Este não. É uma cadeia física sobre séries de reanálise, sem modelo treinado, sem legenda fixa e sem domínio de treino de onde sair. Qualquer área da Terra devolve resposta, e nenhuma resposta falha por ausência de imagem.

O que muda com isso é a pergunta a fazer. Não é se o modelo acertou naquele pixel. É a que escala o número se refere, e contra o que ele foi conferido.

15.1 A célula que responde pela área

O capítulo 2 registrou as duas grades da NASA POWER: radiação do SYN1DEG em célula de um grau, meteorologia do MERRA-2 em célula de $0,5^\circ$ por $0,625^\circ$. Falta a medida do que essa escala custa.

A linha mediu sobre três propriedades do oeste do Paraná. Duas ficam a cerca de 3 km uma da outra e a terceira, 70 km ao sul. As séries dos três pontos foram comparadas dia a dia ao longo de 10 958 dias.

A irradiação global no plano horizontal (GHI) e a direta normal ao feixe (DNI) são idênticas nos três pontos. A diferença máxima é 0,00, e não uma diferença pequena: os três caem na mesma célula de um grau.

A temperatura do ar difere em até $3,06^\circ\text{C}$ e o vento em até $1,55\text{ m s}^{-1}$. A grade meteorológica é mais fina que a de radiação, e separa a terceira propriedade das outras duas.

Comparar o recurso solar de duas áreas de escala de propriedade, com esta fonte, devolve zero por construção. O que a resposta descreve é a célula em que a área caiu.

O que a falta de resolução custa. o Global Solar Atlas resolve irradiação a 250 m. Sobre os mesmos três pontos, a dispersão de GHI que ele vê é de 15 kWh m^{-2} ao ano, ou 0,82 %. Nesses três pontos, o que a célula de um grau deixa de ver é menor que a diferença entre os dois produtos, medida adiante na figura 15.2.

A grade é declarada na resposta. toda resposta solar carrega o campo `grid_note`, que declara as duas grades ao lado do número. Um valor por área apresentado sem isso é lido como local, e não é.

A data em que a série foi buscada. as séries ficam num cache em disco, fora do diretório de trabalho, com chave no par de células, no período e na lista de parâmetros. O cache **não expira**, para que uma figura conferida contra uma execução guardada continue reproduzível. Como a POWER reprocessa dado histórico, uma série guardada pode ser uma revisão superada. Por isso o campo `power_provenance` devolve, para a série diária e para a horária, se ela foi buscada nesta execução ou lida do cache, e em que instante foi obtida.

15.2 O que a série mede

A resposta traz três componentes de irradiação e dois índices. Os dois índices têm nomes próximos e medem coisas distintas.

GHI. o total que chega a uma superfície deitada, somando feixe direto e céu difuso.

DNI. o direto, medido num plano normal ao feixe. Não sofre o fator cosseno da elevação solar, porque o plano de medida acompanha o Sol.

DHI. o difuso, no plano horizontal. É a parcela espalhada pela atmosfera e pela nuvem.

Índice de claridade, K_t . a razão entre o GHI e a irradiação que chegaria ao topo da atmosfera no mesmo instante. Mede transparência atmosférica, e a POWER o publica.

Índice de céu claro. a razão entre a irradiação de todo o céu e a que o mesmo lugar receberia sob céu limpo, somadas as duas sobre a janela. Mede quanto do recurso disponível o céu entregou.




Figura 15.1: A climatologia de trinta anos na célula das três propriedades. **Painel da esquerda, as três componentes,** em quilowatt-hora por metro quadrado por dia, mês a mês: GHI em azul, DNI em laranja e DHI em verde. As duas linhas verticais marcam o mês de maior e o de menor GHI, dezembro e junho, e a razão entre eles está anotada ao lado da curva a que pertence. **O GHI cai por um fator de 2,19 entre os dois meses, e o DNI cai por 1,35.** **Painel da direita, o índice de claridade,** desenhado sobre o intervalo de 0 a 1, que é a faixa do próprio índice. A faixa cinza é o intervalo entre o mês mais claro e o mais fechado do ano. **Ele vai de 0,494 a 0,559,** ou seja, quase não se move enquanto a irradiação cai pela metade.

O ciclo anual do recurso é geométrico, e não atmosférico. Se a nuvem fosse a causa, o índice de claridade cairia junto com o GHI. Ele não cai. O que sobra é o fator cosseno: o Sol mais baixo no inverno, sobre a mesma superfície deitada.

Isso decide uma pergunta de projeto. Inclinar a superfície recupera parte do ciclo anual, porque o que ele tira é ângulo. Nenhuma inclinação recupera perda por nuvem.

15.3 Variabilidade entre anos

Sobre a climatologia diária, a aplicação soma cada ano civil e descreve a série de totais. O padrão são trinta anos, e a POWER publica até o último ano completo.

Na célula das três propriedades, o total anual médio de GHI é de $1\,772 \text{ kWh m}^{-2}$, com desvio-padrão de 61 e coeficiente de variação de 3,4 %. O décimo percentil está em 1 695 e o nonagésimo em 1 849. O ano mais baixo dos trinta foi 2015, com 1 639, e o mais alto foi 2020, com 1 889.

Um coeficiente de variação de 3,4 % põe a incerteza de um projeto neste ponto no produto de radiação e no modelo do sistema, e não na variação do clima entre anos.

A tendência ajustada é de $+0,83 \text{ kWh m}^{-2}$ por ano, com $p = 0,531$. **Trinta anos de série não sustentam afirmação de aumento nem de redução do recurso neste lugar.**

Só ano completo entra. um ano com menos de 365 valores diários é descartado da série de

totais. Um ano parcial soma menos e entraria como ano baixo, enviesando ao mesmo tempo a dispersão e a tendência.

Menos de três pontos não recebem reta. a inclinação e o valor de p voltam como 0 e 1, que se lê como tendência não detectável, e não como uma reta ajustada a dois pontos.

15.4 Inclinação ótima e a tolerância a desvio

Sobre a série horária, cujo padrão são dez anos, a cadeia transpõe a irradiação para um plano inclinado pelo modelo de Perez et al. (1990). Em seguida varre a inclinação de 0° a 45° , em passos de meio grau. O azimute não é varrido: ele é um campo da requisição, e o padrão é 0° , o norte.

Na célula das três propriedades, o máximo cai em $25,0^\circ$, e a latitude do lugar é $25,1^\circ$. A coincidência com a regra da latitude é exata dentro do passo da varredura, e não é a leitura útil da varredura.

Tabela 15.1: A perda por desviar da inclinação ótima, medida sobre a própria varredura. A coluna de cada lado mostra que a curva não é simétrica em torno do máximo: desviar para cima custa um pouco menos que desviar para baixo. A aplicação reporta o pior dos dois lados em cada desvio.

Desvio do ótimo	Perda abaixo do ótimo	Perda acima do ótimo
5°	0,31 %	0,28 %
10°	1,23 %	1,15 %
15°	2,74 %	2,62 %

No ótimo, o plano recebe $1\,883\text{ kWh m}^{-2}$ ao ano, 8,1 % acima do que a superfície deitada recebe. A tabela 15.1 é o que a aplicação devolve ao lado desse número, e ela diz que a curva é achatada.

Uma instalação com 10° de erro de inclinação perde 1,2 % no ano. No mesmo estudo, 20° de desvio do norte custam 0,37 % e 45° custam 2,71 %.

Restrição de terreno, orientação de telhado e custo de estrutura pesam mais na decisão do que perseguir o ótimo geométrico.

15.5 Do plano inclinado ao rendimento

A conversão em energia usa um arranjo de referência de 1 kW de pico, de modo que o resultado é um rendimento específico, independente do tamanho da planta. A cadeia tem quatro passos, e cada um vem de uma publicação.

Perda por ângulo de incidência. o feixe direto é corrigido pela relação de ASHRAE. As duas componentes difusas recebem a mesma relação, integrada sobre o ângulo sólido que cada uma ocupa, seguindo Marion (2017). O céu difuso chega de todo o hemisfério visível, e o difuso refletido pelo solo chega quase rasante. A 26° de inclinação, o termo do solo retém 0,788 contra 0,961 do céu.

Temperatura de módulo. pelo modelo de Faiman (2008), com coeficientes de suporte aberto. Ela depende da irradiação no plano, da temperatura do ar e do vento.

Potência de corrente contínua. pelo modelo PVWatts (Dobos, 2014), com coeficiente térmico de potência de $-0,35\%$ por grau, típico de silício cristalino.

Inversão. pelo modelo PVWatts de inversor, com rendimento nominal de 0,96. Toda a astronomia, a transposição e a modelagem são as implementações de referência da pvlib (Holmgren et al., 2018).

A correção difusa de incidência não é detalhe de implementação. Introduzi-la no sítio de referência do próprio módulo baixou o rendimento específico em 1,62 %. O tamanho do efeito depende de quão difuso é o lugar: sob céu limpo, com fração difusa de 0,14, ele custa 0,75 %. Omiti-la é declarar um rendimento acima do que a cadeia sustenta.

As duas razões de desempenho

A **razão de desempenho** é a energia entregue em corrente alternada dividida pela que o arranjo entregaria com o rendimento de placa. A resposta traz duas, e trocá-las muda o rendimento em cerca de 7 %.

A **razão modelada**, é a que esta cadeia produz. Rodada sobre a série horária de dez anos do ponto de referência, ela dá 0,858.

A **razão aplicada**, é a que multiplica a irradiação no plano para produzir o rendimento reportado. O padrão é 0,80, e quem chama pode substituí-la. A resposta declara qual das duas foi usada.

O rendimento reportado é a irradiação no plano multiplicada pela razão aplicada, e essa conta é exata por construção, e não um fator de correção. Com os $1\,883\text{ kWh m}^{-2}$ do ótimo e a razão de referência, o rendimento sai em cerca de $1\,506\text{ kWh kWp}^{-1}$ ao ano, que corresponde a um fator de capacidade de 17,2 %. Com a razão modelada, o mesmo plano daria 1 616.

O estudo que originou este produto reporta 0,877 para o mesmo ponto, e o número que a aplicação devolve é 0,858. A maior parte da diferença é a correção difusa de incidência descrita acima, que a cadeia do estudo não tinha e que custa os 1,62 % já citados. O restante, cerca de meio ponto percentual, não é explicado por ela. **A aferição da figura 15.2 é da cadeia do estudo**, e a cadeia que a aplicação roda hoje fica abaixo dela, ou seja, mais perto do Atlas.

Uma constante com nome enganoso. o fator de sobredimensionamento do inversor vale 1,15, e ele **não** é uma razão entre corrente contínua e alternada. O que a pvlib recebe é o limite de entrada do inversor, então o arranjo fica em 1 000 watt contra 1 104 de inversor, uma razão de 0,906. O código registra que corrigir a aritmética para uma razão de 1,15 verdadeira moveria um rendimento já aferido em 0,09 %, e por isso o rótulo foi corrigido e a conta não.

15.6 Duas aferições independentes

A pergunta que sobra é se acreditar no número. Ela tem duas metades, e cada uma foi respondida por uma fonte que não compartilha cadeia com a POWER.

A série acompanha o céu

A primeira metade é se a série descreve o céu daquele lugar. A cobertura de nuvem das cenas Sentinel-2, que o catálogo já indexa por cena, é uma observação independente da grandeza que controla o índice de céu claro. O teste é de falsificação: sem relação entre as duas, a série não descreve aquele céu.

Em 134 datas com cena e radiação, a correlação de postos entre nuvem e índice de céu claro é de $\rho = -0,850$. Nas cenas com menos de 10 % de nuvem, o índice de céu claro médio é 0,952; nas com mais de 60 %, é 0,532. A escala favorece a comparação, já que a cobertura de nuvem é reportada por *tile* de 110 km e a célula de radiação mede cerca de $100\text{ km} \times 110\text{ km}$ nessa latitude.

Em cenas com nuvem total, o índice de céu claro varia de 0,1 a 0,9. Isso é esperado. O Sentinel-2 amostra um instante perto das 10h30 locais e o índice é integral do dia inteiro, então uma manhã encoberta seguida de tarde limpa produz exatamente esse par. A concordância é monotônica em mediana, e não preditiva data a data.

Os valores absolutos, contra o Global Solar Atlas

A segunda metade é se os valores estão certos. Uma série pode seguir a nebulosidade e ainda ser enviesada, e responder isso exige referência externa. O Global Solar Atlas (ESMAP, 2020) serve: cadeia de recuperação geoestacionária distinta, resolução de 250 m para irradiação e de 1 km para geração, publicando as mesmas grandezas.




Figura 15.2: A diferença entre a cadeia do estudo e o Global Solar Atlas, nas quatro grandezas que os dois produtos publicam. **Cada barra é a média entre as três propriedades** e os pontos brancos sobre ela são as três, uma a uma. À direita de cada linha estão os valores absolutos dos dois lados, na ordem *estudo contra Atlas*. A cadeia que a aplicação roda hoje é mais recente que a do estudo e devolve razão de desempenho 0,858, abaixo dos 0,877 desenhados aqui e portanto mais perto do Atlas. **As duas grandezas de recurso ficam abaixo da referência**, em azul: a irradiação no plano horizontal por 2,0 % e no plano inclinado por 3,5 %. **As duas de geração ficam acima dela**, em laranja: o rendimento específico por 5,3 % e a razão de desempenho por 9,1 %. A inclinação ótima é de 25° nos dois produtos, e por isso não aparece como barra.

A caracterização do recurso confere. O GHI fica dentro de 2,6 % entre dois produtos que não compartilham sensor nem modelo, e a inclinação ótima é a mesma.

A estimativa de geração é alta, e o excesso está inteiro na razão de desempenho: 0,877 do estudo contra 0,798 do Atlas. É o que se espera de uma cadeia que não modela sujeira, sombreamento entre fileiras, degradação, disponibilidade nem cabeamento. A limitação deixa de ser afirmação e passa a ter tamanho, cerca de 6 % naquela configuração.

É essa medida que fixa a razão de referência de 0,80 como padrão da aplicação. Ela fica perto do valor do Atlas, que inclui os termos de perda que esta cadeia omite.

15.7 A temperatura de módulo depende do vento da reanálise

Uma das três propriedades apareceu com rendimento 2,1 % abaixo das outras duas. Como a irradiação é idêntica nas três, a diferença só podia vir da temperatura de módulo. Ela não veio da temperatura do ar: a diferença diurna entre as células é de 0,16 °C, contra 0,81 m s⁻¹ de diferença de vento.

O campo de vento do MERRA-2 na célula daquela propriedade tem 97,3 % das horas abaixo de $0,5 \text{ m s}^{-1}$ e máximo de $1,08 \text{ m s}^{-1}$ em dez anos. Substituindo o vento por um valor comum às três, a dispersão de rendimento entre elas cai de 2,12 % para 0,02 %.

A diferença não era do lugar. Era do campo de vento.

O viés não se limita àquela célula. O vento das outras duas tem média de $0,75 \text{ m s}^{-1}$ e máximo de $2,94 \text{ m s}^{-1}$ em dez anos, valores baixos para área agrícola aberta. As três estimativas carregam esse viés, e uma delas apenas o torna visível.

Duas áreas que caíam em células meteorológicas distintas podem devolver rendimentos diferentes sem que o lugar tenha qualquer diferença. A cadeia não tem como separar as duas causas, porque não há medida de vento em superfície entrando nela.

15.8 O que não se pode concluir

Que o número descreve a área desenhada. descreve a célula de um grau em que o centroide dela caiu. Duas áreas dentro da mesma célula devolvem séries de radiação idênticas, medidas ao longo de 10 958 dias.

Que o rendimento reportado é previsão de planta. a cadeia omite sujeira, sombreamento entre fileiras, degradação, disponibilidade e cabeamento. Contra o Global Solar Atlas, a estimativa fica de 2,8 % a 6,7 % acima.

Que as duas razões de desempenho são a mesma coisa. a modelada é o que a cadeia produz e a aplicada é o que multiplica a irradiação no plano. Entre 0,858 e 0,80 há 7,3 % de rendimento.

Que o valor absoluto foi aferido contra medida em superfície. não há piranômetro em nenhum dos sítios. A verificação com o Sentinel-2 mostra que a série acompanha a variação do céu, que não é o mesmo que aferir o valor dela.

Que rastreamento está avaliado. a varredura é de sistema fixo. Um eixo de rastreamento alteraria o resultado de forma apreciável neste nível de DNI, e não foi medido.

Que comparar o rendimento de duas áreas compara o lugar. a diferença pode vir do campo de vento da reanálise, como a seção anterior mede.

O modelo de energia e a cascata de perdas

O capítulo 15 terminou com duas razões de desempenho e uma diferença entre elas que não foi explicada, só nomeada. Este capítulo a abre.

A cadeia de energia não busca dado novo. Ela consome a série horária, a transposição e o modelo fotovoltaico que o capítulo anterior descreveu. E faz uma coisa que nenhum outro produto da aplicação faz: **declara, passo a passo, o que ela mediu e o que ela assumiu**.

16.1 Três razões de desempenho, e uma aferição

A resposta traz três razões. Elas não são versões de um mesmo número.

A modelada. é o que esta cadeia calcula: o produto de três fatores medidos sobre a série horária.

A derivada. é a modelada multiplicada pelos termos de perda do PVWatts que a cadeia **não** modela, cada um com um valor declarado.

A aplicada. é a que multiplica a irradiação no plano para produzir o rendimento reportado. O padrão é 0,80, o valor aferido contra o Global Solar Atlas no capítulo 15.

A derivada **não substitui** a aplicada, e a razão é declarada no código: a derivada não tem aferição externa. Ela é a decomposição desta cadeia mais as suposições que ela declara, e as duas coisas não são a mesma.

Uma resolve, todas consomem. há um único ponto em que uma razão de desempenho é decidida, e todas as outras funções recebem o registro que ele devolve, e não um número solto. Um número solto não carrega procedência nem base de relato, e dois produtos alimentados com literais diferentes discordariam na mesma tela sem nada que explicasse. A fronteira de cada produto recusa o número solto.

16.2 A cascata: o que é medido e o que é declarado

A base da cascata é a irradiação global horizontal **da janela horária**, e não a climatologia de trinta anos. As duas aparecem lado a lado na figura porque diferem: 1783 kWh m^{-2} contra 1772 kWh m^{-2} , 0,65 % de diferença.

Começar a cascata pela climatologia deixaria **toda** razão abaixo dela errada pela diferença entre as duas janelas. A aplicação rotula as duas em vez de reconciliá-las, porque são produtos diferentes sobre períodos diferentes.

O passo que não é perda de planta

O segundo passo da cascata custa 2,33 % e não é perda nenhuma.

A NASA POWER publica GHI, DNI e DHI, e os três **não fecham**: o plano horizontal reconstruído a partir do direto e do difuso não reproduz o global publicado. A cadeia usa a reconstrução, porque é dela que a transposição parte, e carrega a diferença como linha própria, fora da razão de desempenho.

Não é artefato de Sol baixo. Restringindo a elevações solares acima de 10° , o resíduo fica da mesma ordem. É propriedade do produto de radiação, e uma razão de desempenho que o absorvesse estaria cobrando da planta um resíduo do dado.




Figura 16.1: Uma execução da cadeia de energia sobre dez anos de série horária, no ponto de referência do capítulo 15. **Painel da esquerda, a cascata:** cada barra vai da energia antes do passo até a energia depois dele, e o fator do passo está anotado ao lado. **A cor diz a natureza do passo,** e é a leitura da figura: azul, medido por esta cadeia sobre a série; laranja, valor declarado que ela não modela e que o usuário pode editar; verde, propriedade do produto de radiação, que fica fora da razão de desempenho. O losango marca a base, e a linha tracejada à esquerda dele é a climatologia de trinta anos, que é outra janela e outro produto. As três últimas linhas não têm barra porque estão no padrão, que é fator 1,000. A unidade muda na linha *Mudança de unidade*, e as duas metades só são numericamente contínuas porque o arranjo de referência é de 1 000 W a 1 000 W m⁻². **Painel da direita, as quatro razões de desempenho** que a resposta carrega, contra a faixa cinza-verde que o Global Solar Atlas implica sobre os mesmos sítios. A modelada é 0,858, a derivada 0,784, a derivada com os dois termos opcionais ligados nos valores sugeridos pelo PVWatts é 0,737, e a aplicada é 0,800.

Os três fatores medidos, e a identidade que é exigida

Entre a irradiação no plano e a energia em corrente alternada há três fatores que esta cadeia mede: incidência (0,971 3), temperatura de célula (0,923 9) e inversor (0,956 3).

O produto deles é a razão modelada, 0,858 2, por construção. A aplicação não confia nisso: ela calcula o resíduo entre o produto dos três e a razão direta, e **levanta erro** se ele passar de 1×10^{-9} . Na execução da figura o resíduo é da ordem de 1×10^{-16} .

Por que levantar em vez de avisar. um resíduo diferente de zero significa que o quadro não veio de uma cadeia só. Se isso acontecer, todo número abaixo dele está errado, e um aviso seria lido como ressalva.

Os seis termos declarados

Depois dos medidos vêm seis valores que a cadeia não modela e declara: sujeira 2 %, descasamento entre módulos 2 %, cabeamento 2 %, conexões 0,5 %, tolerância de placa 1 % e degradação inicial por luz 1,5 %. Juntos valem 8,68 %, e todos são editáveis.

Dois outros termos existem e são **zero por padrão**: sombreamento entre fileiras e disponibilidade da planta.

O padrão zero não é omissão, e a justificativa é medida. Ligá-los nos 3 % que o PVWatts sugere leva a razão derivada a 0,737, que é 7,4 % *abaixo* do piso da faixa do Atlas. Não há geometria de fileiras nesta cadeia, então não há de onde calcular um sombreamento entre elas.

As perdas são mostradas multiplicadas no total. e não na posição física de cada uma. O custo dessa apresentação foi medido: colocá-las fisicamente dá $1\,476,20 \text{ kWh kWp}^{-1}$ contra $1\,474,73 \text{ kWh kWp}^{-1}$ na forma plana, 0,10 %. As energias de cada linha são apresentação da pilha de fatores, e não uma simulação refeita.

16.3 A maior perda medida, e o vento na altura errada

A temperatura de célula é a maior perda modelada da cascata: 0,923 9, ou 7,6 %. Ela depende da irradiação no plano, da temperatura do ar e do vento, e é aí que está o problema.

O coeficiente de vento do modelo de Faiman (2008) é calibrado contra vento medido **na altura do módulo**. Esta cadeia alimenta o modelo com o vento a 2 m da reanálise.

É a altura errada para aquele coeficiente, e o viés é sistemático, **independente de qualquer defeito do sítio**. Ele fica dentro da razão modelada, que é onde toda figura de energia deste capítulo está ancorada.

Isso é distinto do que o capítulo 15 mediu. Lá, o campo de vento de uma célula era implausível e produzia uma diferença entre sítios que não existia. Aqui, a altura de medida está errada em todos os sítios, inclusive naqueles em que o campo de vento é plausível. A aplicação declara o viés e não o quantifica, porque não tem contra o que medi-lo.

O tipo de módulo também é escolha, e não medida. o coeficiente térmico de potência vem de uma seleção entre três tipos do PVWatts: $-0,004\,7$, $-0,003\,5$ e $-0,002\,0$ por grau. A aplicação usa o segundo, que é a opção **menos conservadora** entre as de silício cristalino, e por isso nomeia a seleção em toda resposta e carrega as alternativas ao lado.

16.4 Degradação é base de relato, e não linha de perda

A cadeia oferece duas bases. Na de *ano um* o fator é 1,000. Na de *média de vida* ele é a média de $(1 - r)^t$ ao longo do período de análise, que no padrão de 0,5 % ao ano e vinte e cinco anos dá

0,942 2, ou 5,78 % a menos.

As duas bases não são comparáveis entre si nem com uma referência externa calculada na outra. Um rendimento de média de vida lido contra uma banda de excedência de ano um mistura duas convenções, e por isso toda figura de energia imprime a base em que foi calculada.

Zero por ano é um valor. um pedido que declare degradação nula é uma afirmação, e não uma omissão. O código registra que, quando isso era tratado como ausência, o padrão de 0,5 % voltava por baixo e multiplicava toda figura de média de vida por 0,942 2 em vez de 1,0.

16.5 Rastreamento: a resposta inverte com a base




Figura 16.2: Rastreamento de eixo único horizontal contra a inclinação fixa, na mesma execução da figura 16.1. **Painel da esquerda:** a mesma série, a mesma razão de desempenho e o mesmo sítio, em duas bases. Por quilowatt-pico instalado o rastreador entrega 19,7 % a mais; por hectare de sítio, com o par de razões de cobertura do solo que a aplicação traz por padrão, ele entrega 18,9 % a menos. **Painel da direita:** a energia por hectare do rastreador em relação à do fixo, contra a razão de cobertura do solo do rastreador. A linha cinza é a paridade. A tracejada laranja é o padrão da aplicação, 0,295; a verde é a razão em que a curva cruza a paridade, 0,368, que o produto resolve numericamente. **O sinal da comparação por hectare é fixado por esse parâmetro**, e não pelo sítio.

Por quilowatt-pico o rastreador ganha e não inverte em nenhuma configuração testada. Por hectare ele perde, com o par de razões de cobertura padrão. As duas bases respondem perguntas diferentes. Quem lê só a primeira acha que leu a resposta.

As medições publicadas discordam do sinal

A pergunta por hectare foi medida diretamente sobre plantas construídas, por duas fontes, e elas não concordam.

Bolinger e Bolinger (2022) publica densidade de energia sobre a área direta do arranjo: 447 MWh contra 394 MWh por acre ao ano, ou -11,9 % para o rastreamento.

Ong et al. (2013) publica variação da intensidade de uso do solo. Nos sítios de irradiação direta mais próxima deste, ela vai de -4,9 % a -2,7 %, e o sinal negativo significa que o rastreamento usa *menos* terra por unidade de energia.

As duas medem a mesma pergunta e apontam para lados opostos. A aplicação as reporta separadas, cada uma na precisão da sua fonte, e **não tira média delas**. A linha derivada do modelo é uma terceira, apresentada com o par de parâmetros que a produziu.

De onde vêm as razões de cobertura. não são números sem fonte. Elas saem das densidades de capacidade publicadas por Bolinger e Bolinger (2022), convertidas para hectare e divididas pela potência de placa de um hectare inteiramente coberto na eficiência de módulo adotada. O resultado é 0,432 4 para o fixo e 0,296 5 para o rastreador. Os padrões da aplicação são esses valores a três casas, e a resposta reporta o resíduo. O padrão do rastreador já foi 0,35, sem fonte, 18 % acima do que aquele mesmo trabalho implica, o que movia a manchete por hectare em cerca de catorze pontos percentuais.

O ganho anual é um ganho de verão. na execução da figura, os 19,7 % anuais se decompõem em 36,1 % no verão e 1,5 % no inverno. Quem dimensiona para uma carga limitada pelo inverno lê o número anual para uma estação em que a comparação é quase neutra.

O que não está no modelo. consumo dos motores, disponibilidade do controlador e parada mecânica, todos os quais o rastreador carrega e o arranjo fixo não. Custo de capital e de operação também não. A comparação é de energia, e não sustenta sozinha uma decisão de projeto.

16.6 Quando a energia chega

O perfil de geração responde a distribuição no dia e no ano, e três detalhes dele decidem se ele pode ser lido.

A hora é UTC salvo pedido. os valores da POWER são médias horárias rotuladas pela hora de início, em UTC. Um deslocamento para hora local é aplicado só se o chamador o informar, e a resposta declara qual foi. Sem isso um pico de meio-dia cai na hora errada.

As horas de sol pleno são no plano do módulo. e não no horizontal, que é o plano em que a maioria das fontes as publica. É o mesmo plano em que o rendimento é calculado.

O nível não é um rendimento. o perfil é calculado sobre a série modelada em corrente alternada **antes** de qualquer razão de desempenho. A forma é a do modelo; o nível não é um número reportável.

16.7 Da área à capacidade, e a base que decide

A área apta entra na cadeia de fora, e a conversão dela em capacidade instalada passa por uma densidade que precisa ser declarada junto.

Sete bases, e elas não medem a mesma coisa. entre a mais baixa e a mais alta há 0,427 3 e 0,864 9 MW de corrente contínua por hectare, **um fator de dois**. A diferença está em duas escolhas: área direta do arranjo contra área total do sítio, e fixo contra rastreador.

Um raster de aptidão classifica terreno inteiro, incluindo o que viraria estrada, espaçamento e subestação. Os hectares dele são área *total de sítio*. Aplicar a eles uma densidade de *área direta de arranjo* trata o polígono todo como pegada de módulo.

A fração construível é exemplo, não mediana. o valor de 0,75 que converte área direta em área total é o exemplo trabalhado do próprio artigo, e não uma mediana medida sobre a frota.

Duas razões parecidas que não são a mesma. a razão entre corrente contínua e alternada da frota, 1,314 1, serve **apenas** para converter uma densidade publicada em corrente alternada para contínua. Ela não é o fator de sobredimensionamento do inversor que o capítulo 15 descreveu. São grandezas sem relação, e a proximidade numérica é coincidência.

As três classes nunca são somadas. a área apta sem conflito de uso é a única que alimenta a manchete. A área apta em conflito com lavoura anual é reportada à parte, porque não é capacidade adicional: é a mesma terra, contada contra a produção de alimento. A área de declividade restritiva é reportada só como área, porque as referências de densidade não cobrem a estrutura que ela exigiria.

Um hectare espalhado não hospeda a planta. junto de toda figura de capacidade vem o maior bloco contíguo da classe e quantos blocos existem, com conectividade de oito. Uma área somada de muitos retalhos pequenos não sustenta a aritmética que a converteu em megawatt.

O sombreamento entra na base errada se não for convertido. a perda de horizonte que o produto de terreno publica é fração da irradiação **direta**. Um total no plano do módulo é direta mais difusa, então a perda precisa ser escalada pela fração direta antes de chegar ao rendimento. No sítio de referência, com fração direta de 0,642 5, uma perda média de 3 % no feixe vale 0,980 72 sobre o total, e não 0,970 00. Sem a fração direta declarada, a aplicação **recusa** aplicar o desconto em vez de aplicá-lo sobre a base errada.

16.8 A banda de excedência, e o que ela não contém

Sobre os totais anuais, a cadeia devolve fatores de excedência. Na execução da figura, com trinta anos completos, o P90 é 0,956 5 da média: a banda inteira, do P50 ao P90, vale 4,35 %.

P90 é o valor excedido em noventa por cento dos anos, e por isso fica abaixo do P50. O cartão de recurso reporta percentis estatísticos, em que o nonagésimo é o valor alto. As duas convenções aparecem na mesma tela, e a resposta traz a tabela de correspondência: a excedência P90 e o décimo percentil estatístico são a mesma estimativa da mesma quantidade.

O estimador aplicado é o empírico, o mesmo que o cartão de recurso usa, para que os dois não possam se contradizer. O ajuste normal é reportado ao lado, com um teste de Shapiro-Wilk da normalidade que ele assume, e não aplicado. Nesta execução o teste dá $p = 0,916$.

A banda propaga **uma** fonte de incerteza: a variabilidade medida do recurso entre anos. Ficam de fora oito termos, e a resposta os nomeia um a um. O viés do produto de radiação contra medida em superfície, o erro do modelo de transposição e fotovoltaico, a incerteza da razão de desempenho, a variação de sujeira, a degradação, a disponibilidade, o sombreamento entre fileiras e a base de densidade de capacidade. Ela é, portanto, **mais estreita que um P90 de financiamento de projeto**, e a resposta afirma isso no próprio campo.

Há uma comparação que decide como ler a banda. A escolha da base de densidade move o resultado em 102 %; a banda de excedência inteira o move em 4,35 %.

16.9 O que não se pode concluir

Que a razão derivada é melhor que a aplicada. a derivada é a decomposição desta cadeia mais as suposições declaradas, e fica 1,55 % abaixo do piso da faixa do Atlas. A aplicada é a única com aferição externa. As duas são corretas sob a suposição de cada uma.

Que a razão modelada pode ser citada como razão de desempenho de planta. ela não inclui nenhum dos seis termos declarados, e está 7,3 % acima da aplicada. É o rendimento de uma planta sem sujeira, sem descasamento, sem cabeamento e sem tolerância de placa.

Que o ganho do rastreador é o que a manchete diz. depende da base. Na mesma execução são 19,7 % por quilowatt-pico e -18,9 % por hectare, e as duas medições publicadas da pergunta por

hectare discordam do sinal entre si.

Que a capacidade reportada é interconectável. é um teto de recurso e de terra. Não há consulta à rede, nem licenciamento, nem verificação de reserva legal, e as áreas de classe herdaram as convenções de aptidão sob as quais foram produzidas.

Que a banda de excedência é a incerteza do projeto. ela contém só a variabilidade do recurso entre anos. Oito termos declarados ficam de fora, e um deles, a base de densidade, move o resultado vinte e três vezes mais que a banda inteira.

Que a energia é linear na irradiação anual. a excedência a trata assim, e isso é primeira ordem. A razão entre o plano inclinado e o horizontal depende da fração difusa, que varia entre anos, e a saída fotovoltaica é levemente sublinear na irradiância por efeito de temperatura.

Referências

- Barnes, R., Lehman, C., Mulla, D. (2014). Priority-flood: an optimal depression-filling and watershed-labeling algorithm for digital elevation models. *Computers & Geosciences*, 62, 117–127.
- Bolinger, M., Bolinger, G. (2022). Land requirements for utility-scale PV: an empirical update on power and energy density. *IEEE Journal of Photovoltaics*, 12(2), 589–594. Amostra de 736 usinas e 35 482 MW de corrente contínua, em operação comercial entre 2007 e 2019, nos Estados Unidos.
- Brown, L. D., Cai, T. T., DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science*, 16(2), 101–133.
- Dobos, A. P. (2014). *PVWatts version 5 manual*. NREL/TP-6A20-62641, National Renewable Energy Laboratory, Golden, CO.
- Doelling, D. R., Haney, C. O., Scarino, B. R., Gopalan, A., Bhatt, R. (2016). Advances in geostationary-derived longwave fluxes for the CERES synoptic (SYN1deg) product. *Journal of Atmospheric and Oceanic Technology*, 33(3), 503–521.
- European Space Agency (2021). *Sentinel-2 Products Specification Document*, PSD v14.9. Processing baseline 04.00, em produção desde 25 de janeiro de 2022.
- Energy Sector Management Assistance Program (2020). *Global Solar Atlas 2.0*. Banco Mundial, Washington, DC. Dados modelados pela Solargis.
- Faiman, D. (2008). Assessing the outdoor operating temperature of photovoltaic modules. *Progress in Photovoltaics: Research and Applications*, 16(4), 307–315.
- Feyisa, G. L., Meilby, H., Fensholt, R., Proud, S. R. (2014). Automated Water Extraction Index: a new technique for surface water mapping using Landsat imagery. *Remote Sensing of Environment*, 140, 23–35.
- Gelaro, R., McCarty, W., Suárez, M. J., et al. (2017). The Modern-Era Retrospective analysis for Research and Applications, version 2 (MERRA-2). *Journal of Climate*, 30(14), 5419–5454.
- Gretton, A., Borgwardt, K. M., Rasch, M. J., Schölkopf, B., Smola, A. (2012). A kernel two-sample test. *Journal of Machine Learning Research*, 13, 723–773.
- Holmgren, W. F., Hansen, C. W., Mikofski, M. A. (2018). pvlib python: a python package for modeling solar energy systems. *Journal of Open Source Software*, 3(29), 884.
- Jordan, D. C., Kurtz, S. R. (2013). Photovoltaic degradation rates: an analytical review. *Progress in Photovoltaics: Research and Applications*, 21(1), 12–29. A taxa adotada pela aplicação é a mediana de silício cristalino.
- Kopp, G., Lean, J. L. (2011). A new, lower value of total solar irradiance: evidence and climate significance. *Geophysical Research Letters*, 38, L01706.
- Marion, B. (2017). Numerical method for angle-of-incidence correction factors for diffuse radiation incident photovoltaic modules. *Solar Energy*, 147, 344–348.

- McFeeters, S. K. (1996). The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features. *International Journal of Remote Sensing*, 17(7), 1425–1432.
- Melo, J. L. S., Magalhães, D. K., Kolodziej, J. E., Kuhn, E. V. (2026). Automatic Land Cover Classification with Sentinel-2 and MapBiomas Time Series. *XLIV Simpósio Brasileiro de Telecomunicações e Processamento de Sinais (SBrT)*, Salvador, BA.
- Nobre, A. D., Cuartas, L. A., Hodnett, M., Rennó, C. D., Rodrigues, G., Silveira, A., Waterloo, M., Saleska, S. (2011). Height Above the Nearest Drainage: a hydrologically relevant new terrain model. *Journal of Hydrology*, 404(1–2), 13–29.
- Olofsson, P., Foody, G. M., Herold, M., Stehman, S. V., Woodcock, C. E., Wulder, M. A. (2014). Good practices for estimating area and assessing accuracy of land change. *Remote Sensing of Environment*, 148, 42–57.
- Ong, S., Campbell, C., Denholm, P., Margolis, R., Heath, G. (2013). *Land-use requirements for solar power plants in the United States*. NREL/TP-6A20-56290, National Renewable Energy Laboratory, Golden, CO.
- Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62–66.
- Perez, R., Ineichen, P., Seals, R., Michalsky, J., Stewart, R. (1990). Modeling daylight availability and irradiance components from direct and global irradiance. *Solar Energy*, 44(5), 271–289.
- Pontius, R. G., Millones, M. (2011). Death to Kappa: birth of quantity disagreement and allocation disagreement for accuracy assessment. *International Journal of Remote Sensing*, 32(15), 4407–4429.
- Ramdas, A., Reddi, S. J., Póczos, B., Singh, A., Wasserman, L. (2015). On the decreasing power of kernel and distance based nonparametric hypothesis tests in high dimensions. *AAAI Conference on Artificial Intelligence*, 29(1).
- Strobl, C., Boulesteix, A.-L., Zeileis, A., Hothorn, T. (2007). Bias in random forest variable importance measures: illustrations, sources and a solution. *BMC Bioinformatics*, 8, 25.
- Xu, H. (2006). Modification of Normalised Difference Water Index (NDWI) to enhance open water features in remotely sensed imagery. *International Journal of Remote Sensing*, 27(14), 3025–3033.

As ações do sidecar

Tudo o que o TERRA calcula passa por um processo Python separado, o *sidecar*. Ele não é um serviço. O lado Go escreve **um** objeto JSON na entrada padrão e lê **um** resultado JSON na saída padrão; progresso e erro saem como linhas JSON na saída de erro. Um campo da requisição, o *action*, escolhe o que será respondido.

A lista é o contorno exato do que a aplicação sabe fazer. O capítulo 1 afirma que não há álgebra de mapas no TERRA; a tabela abaixo é onde essa afirmação se confere, num catálogo só.

Tabela A.1: As dezessete ações, agrupadas por produto. A ordem é a da tabela ACTIONS no código, reagrupada para leitura.

action	O que responde
<i>Cobertura do solo</i>	
predict	a classificação completa: cenas, atributos, modelo, mapa, estatística por classe, série de índices e fenologia. Quando a área intersecta o Brasil, também a comparação com o MapBiomas
lulc	só a análise descritiva do MapBiomas, sem classificar
list_datacube	que cenas a janela e os filtros devolvem, sem ler banda nenhuma
render_composite	uma composição de bandas para desenhar no mapa
<i>Erro e transferência</i>	
domain_shift	a distância entre duas execuções, a partir das impressões digitais gravadas na classificação
domain_shift_cohort	a mesma medida sobre um conjunto de execuções, e não sobre um par
<i>Água e terreno</i>	
water	a máscara de água por índice espectral, data a data
flood_envelope	a envoltória de cheia: a cadeia HAND sobre quatro produtos de elevação, e o raster de concordância entre eles
<i>Energia</i>	
solar_resource	o recurso solar no centroide da área
solar_terrain	a irradiação distribuída sobre a declividade e a orientação do terreno
solar_siting	onde dentro da área uma usina pode ser posta
energy_model	o rendimento, com cada termo de perda declarado
wind_resource	a triagem do recurso eólico, com os diagnósticos que a qualificam
<i>Dossel</i>	
canopy_field	o talhão simulado: idade, área foliar e o balanço de luz ao longo da estação
canopy_from_aoi	o mesmo, partindo da série que a área já produziu
canopy_mesh	a malha tridimensional do dossel, para desenho
<i>Serviço</i>	
ping	se o interpretador importa o que o sidecar precisa

Uma requisição que não nomeia ação nenhuma roda a classificação. Uma requisição que nomeia uma ação **inexistente** também, porque o despacho é `ACTIONS.get(action, action_predict)`. É o comportamento herdado da cadeia de `if` que a tabela substituiu, e o código o documenta como deliberado.

Para quem chama o sidecar por script, a consequência é que um erro de digitação em `action` não devolve erro. Devolve uma classificação, que custa minutos e não é o que foi pedido.

O que não está aqui. os campos de requisição de cada ação. Eles ficam no capítulo do produto e, em forma canônica, em `internal/analysis/types.go` do *geosense-infer*. Uma tabela de campos aqui envelheceria a cada campo novo, e referência errada é pior que referência ausente.

Divergência conhecida. o `docs/API.md` do *geosense-infer* lista quatro dessas ações. A tabela acima é a do código.

Procedência, capítulo a capítulo

Cada afirmação deste livro sai de um arquivo, de um estudo ou de uma publicação. Esta tabela é a lista completa, capítulo a capítulo.

Ela responde uma pergunta que o corpo do texto não responde bem: **o que deste livro você consegue abrir sozinho?** A terceira coluna diz onde cada entrada vive, e a contagem abaixo é o resumo dela.

Tabela B.1: Onde vivem as 119 entradas de procedência deste livro.

Onde isso vive	Entradas	O que isso significa para quem lê
Aplicação	85	<i>geosense-infer</i> , público sob GPL v3. Arquivo, função ou constante que se abre sem pedir nada a ninguém
Livro	15	Os <i>scripts</i> de figura deste livro e os dados que eles guardam em cache
Linha	10	<i>TERRA-Research</i> , privada. Nomeada pelo apelido, e o estudo pode ser solicitado; a seção 1.1 diz para quem
Publicado	9	Literatura, na bibliografia deste livro

De 119 entradas, 85 apontam para o código público da aplicação e 10 para a linha privada. O que sustenta este livro é, em quase toda parte, coisa que o leitor pode abrir.

A tabela B.2 é impressa em folha deitada porque a coluna do meio carrega caminho de arquivo e nome de função, que não hifenizam.

Tabela B.2: A procedência de cada capítulo. *O que* é o elemento; *onde vive* é a coluna da tabela B.1; *onde está* é o arquivo, a função ou o estudo.

Cap.	O que	Onde vive	Onde está
Capítulo 1 <i>O que o TERRA entrega, e de onde vem</i>			
1	Escopo do produto	Aplicação	README.md do <i>geosense-infer</i> , versão 0.4.0
1	As 17 ações	Aplicação	tabela ACTIONS em <i>sidecar/infer.py</i>
1	Qualificação do vento	Aplicação	RESULT_QUALIFIER e data_quality em <i>sidecar/wind.py</i>
1	Aferição do solar	Aplicação	a nota sobre o Global Solar Atlas na abertura de <i>sidecar/solar.py</i>
1	Tabelas 1.1 e 1.2	Linha	índice de estudos e notas de triagem da linha <i>TERRA-Research</i> , agosto de 2026
Capítulo 2 <i>O protocolo comum: área, catálogo e janela</i>			
2	Catálogo e bandas	Aplicação	<code>list_stac_products</code> em <i>sidecar/infer.py</i>
2	Cadência mensal	Aplicação	o bloco <code>monthly_best</code> da mesma função
2	Reamostragem	Aplicação	<code>load_band_to_reference_grid</code> , <code>bilinear</code>
2	As 22 datas	Aplicação	<code>build_feature_matrix</code> , e <code>on_dates_model</code> da ação de predição
2	A cena do meio	Aplicação	<code>products[len(products) // 2]</code> , nos caminhos do <i>Temporal Transformer</i> e do Prithvi
2	Elevação, cheia	Aplicação	COLLECTIONS e DEFAULT_IDS em <i>sidecar/dem.py</i>
2	Elevação, solar	Aplicação	DEM_COLLECTION e <code>fetch_dem</code> em <i>sidecar/solar.py</i>
2	Padrões da interface	Aplicação	<code>maxCloud</code> e <code>monthlyBest</code> em <i>frontend/src/App.tsx</i>
Capítulo 3 <i>Do número gravado ao número que o modelo vê</i>			
3	As constantes	Aplicação	em <i>sidecar/infer.py</i> : <code>QUANTIFICATION_VALUE</code> , <code>BOA_ADD_OFFSET</code> , <code>BOA_OFFSET_FIRST_BASELINE</code> , <code>BOA_OFFSET_FIRST_DATE</code>
3	As duas conversões	Aplicação	<code>to_reflectance</code> e <code>as_trained</code> , no mesmo arquivo, com as <i>docstrings</i> que justificam a costura
3	Conjunto de treino	Aplicação	22 produtos, 2024-05-04 a 2026-01-04, <i>tiles</i> T21JZN e T22JBT, declarados na <i>docstring</i> de <code>as_trained</code>
3	A medição de 2021 vs 2024	Linha	nota de correção da linha <i>TERRA-Research</i> sobre o offset de refletância
3	Referência	Publicado	ESA (2021), para a <i>baseline</i>
Capítulo 4 <i>Os três caminhos de modelo, e a legenda fixa</i>			
4	As cinco classes	Aplicação	<code>model/label_encoder.joblib</code> , vetor [3, 21, 25, 39, 41]

Tabela B.2, continuação

Cap.	O que	Onde vive	Onde está
4	Os 80 atributos	Aplicação	model/feature_names.joblib
4	Como são montados	Aplicação	build_feature_matrix em sidecar/infer.py
4	O padrão da aplicação	Aplicação	model_kind com queda para spectral, em sidecar/infer.py
4	O Transformer	Aplicação	NUM_FRAMES, N_BANDS e band_specs em sidecar/temporal_transformer.py
4	A regra do modo	Aplicação	modeBlockedBy em frontend/src/lib/classifyOptions.ts
4	As duas figuras	Livro	figuras/figuras.py, que lê o artefato e o CSV da ablação sem transcrever número
4	A ablação	Linha	estudo de representação da linha <i>TERRA-Research</i> , cenários A e agrupado, sobre MapBiomias real

Capítulo 5 *O que o mapa afirma, e em que unidade*

5	As estatísticas por classe	Aplicação	class_statistics em sidecar/infer.py
5	O tamanho da célula	Aplicação	reference_pixel_size_m, no mesmo arquivo, lido do <i>transform</i> da grade
5	A grade de referência	Aplicação	construída de B04 na resolução nativa, no caminho de predição
5	A confiança, RF	Aplicação	classify_from_features em sidecar/infer.py
5	A confiança, TT	Aplicação	predict_pixels em sidecar/temporal_transformer.py
5	O piso da escala	Aplicação	confidence_floor, com o comentário que justifica reportá-lo junto da média
5	O modo temporal	Aplicação	o laço de pilha cumulativa da ação de predição
5	A figura 5.1	Livro	figuras/figuras.py, que lê o número de classes do <i>label encoder</i> embarcado

Capítulo 6 *Concordância com o MapBiomias: a matriz e seus intervalos*

6	A comparação	Aplicação	agreement_against_reference em sidecar/lulc.py
6	A unidade de amostragem	Aplicação	a <i>docstring</i> da mesma função, que registra o fator de nove pixels por célula
6	As três acurácias	Aplicação	o laço por classe da mesma função, com producers_pct e users_pct
6	O intervalo	Aplicação	_wilson_interval, no mesmo arquivo
6	Fora da legenda	Aplicação	o contador outside, reportado como n_outside_legend
6	A figura 6.1	Livro	figuras/figuras.py, que executa a função de intervalo do próprio sidecar em vez de reimplementá-la
6	Referência	Publicado	Brown et al. (2001), sobre por que Wilson e não Wald

Tabela B.2, continuação

Cap.	O que	Onde vive	Onde está
Capítulo 7 <i>Quantidade e alocação: dois erros que não se somam</i>			
7	A decomposição	Aplicação	o bloco de quantidade e alocação em <code>agreement_against_reference</code> , em <code>sidecar/lulc.py</code>
7	Os campos do payload	Aplicação	<code>quantity_disagreement_pct</code> e <code>allocation_disagreement_pct</code>
7	Por que o kappa fica fora	Aplicação	o comentário imediatamente acima do bloco, no mesmo arquivo
7	O defeito que ela corrige	Aplicação	a <i>docstring</i> da mesma função, que registra o painel de composição mostrando o termo de quantidade sozinho
7	A figura 7.1	Livro	<code>figuras/figuras.py</code> , que extrai o bloco de decomposição do <code>sidecar</code> e o executa sobre matrizes sintéticas
7	Referência	Publicado	Pontius e Millones (2011)
Capítulo 8 <i>Concordância por blocos: onde a discordância está</i>			
8	A grade e o piso	Aplicação	<code>BLOCKS_PER_SIDE</code> e <code>MIN_BLOCK_CELLS</code> em <code>sidecar/lulc.py</code> , cada um com a justificativa no comentário
8	As estatísticas	Aplicação	<code>_block_agreement</code> , no mesmo arquivo
8	Não ser um teste	Aplicação	a <i>docstring</i> dessa função, que declara o espalhamento como descritivo
8	A figura 8.1	Livro	<code>figuras/figuras.py</code> , que lê o número de blocos por lado e o piso do próprio <code>sidecar</code>
8	Referência	Publicado	Olofsson et al. (2014), para o que seria uma avaliação com desenho amostral
Capítulo 9 <i>Separabilidade de classes: contraste e assinatura</i>			
9	As duas distâncias	Aplicação	<code>bhattacharyyaGaussian</code> e <code>jeffriesMatusita</code>
9	Onde elas vivem	Aplicação	<code>frontend/src/lib/separability.ts</code>
9	As duas leituras	Aplicação	a abertura do mesmo arquivo, que separa contraste de assinatura
9	O máximo sobre bandas	Aplicação	o campo <code>best</code> da mesma implementação, com a razão no comentário
9	O espectro por classe	Aplicação	<code>class_spectra</code> em <code>sidecar/infer.py</code> , com <code>SPECTRUM_MIN_PIXELS</code>
9	As sete bandas	Aplicação	<code>TERRA_BANDS</code> , no mesmo arquivo
9	A figura 9.1	Livro	<code>figuras/figuras.py</code> , que executa as funções do próprio <code>frontend</code> em vez de reimplementá-las
9	O par 0,059 e macro-F1 0,81	Linha	estudo de teto multifonte da linha <i>TERRA-Research</i>

Tabela B.2, continuação

Cap.	O que	Onde vive	Onde está
Capítulo 10 <i>Deslocamento de domínio: o diagnóstico</i>			
10	A impressão digital	Aplicação	build_fingerprint em sidecar/domain_shift.py
10	As três distâncias	Aplicação	kl_divergence, cva_magnitude e mmd_rbf, no mesmo arquivo
10	Por que o núcleo é gaussiano	Aplicação	a <i>docstring</i> de mmd_rbf, que registra a redundância e a cegueira do linear
10	A tabela por atributo	Aplicação	feature_shift_table
10	A padronização	Aplicação	_standardise, em desvios de treino
10	A figura 10.1	Livro	figuras/figuras.py, que importa o módulo do sidecar e chama as duas funções
10	Referências	Publicado	Gretton et al. (2012) para o núcleo característico, Ramdas et al. (2015) para a queda de poder com a dimensão, Strobl et al. (2007) para o viés da importância por impureza
Capítulo 11 <i>Deslocamento de domínio: o que ele não corrige</i>			
11	As seis famílias	Linha	estudo de transferência real da linha <i>TERRA-Research</i> , par Iowa e oeste do Paraná
11	O experimento construído	Linha	estudo sintético da mesma linha, com o deslocamento montado por mecanismo nomeado
11	O teto com rótulo de declaração	Linha	estudo de arquitetura multifonte, que troca a referência do destino
11	A adaptação fora de escopo	Aplicação	a abertura de sidecar/domain_shift.py
11	A figura 11.1	Livro	figuras/figuras.py, que lê o CSV do estudo real e a tabela do relatório do sintético
Capítulo 12 <i>Água superficial por índice espectral</i>			
12	Os três índices	Aplicação	compute_water_indices em sidecar/water.py
12	O limiar	Aplicação	otsu_threshold e otsu_threshold_for_date, no mesmo arquivo
12	A validade por data	Aplicação	per_date_valid_mask, cuja <i>docstring</i> registra a medição da figura 12.1
12	A ocorrência	Aplicação	occurrence_map e classify_occurrence
12	Referências	Publicado	McFeeters (1996) para o NDWI, Xu (2006) para o MNDWI, Feyisa et al. (2014) para o AWEI e Otsu (1979) para o limiar
Capítulo 13 <i>A cadeia de terreno: da grade ao HAND</i>			
13	A cadeia	Aplicação	sidecar/hand.py, com as cinco verificações analíticas em sidecar/tests/test_hand.py
13	O preenchimento	Aplicação	fill_depressions, Priority-Flood com épsilon

Tabela B.2, continuação

Cap.	O que	Onde vive	Onde está
13	A direção de fluxo	Aplicação	d8_receivers, e a moldura de infinito positivo
13	A altura	Aplicação	a função hand, que mede contra o DEM original
13	Os quatro produtos	Aplicação	COLLECTIONS e DEFAULT_IDS em sidecar/dem.py
13	A margem e a mescla	Aplicação	a abertura de sidecar/dem.py
13	A figura 13.1	Livro	figuras/figuras.py, que roda a cadeia do sidecar sobre o DEM real do baixo Taquari
13	A tabela 13.1	Livro	a mesma origem, medida e cacheada em figuras/dados/limiar-drenagem.csv
13	O dado	Linha	Copernicus GLO-30, recorte que o estudo de cheia da linha baixou; as camadas que a figura desenha ficam em figuras/dados/terreno-taquari.npz
13	Referências	Publicado	Nobre et al. (2011) para o HAND, Barnes et al. (2014) para o Priority-Flood

Capítulo 14 *A envoltória: o raster de concordância*

14	A medição	Aplicação	measure em sidecar/flood.py
14	O raster	Aplicação	agreement_raster, no mesmo arquivo
14	O índice	Aplicação	a função iou, com a nota sobre o CSI
14	O anel	Aplicação	inset_mask e resolve_inset_margin
14	Os limiares	Aplicação	THRESHOLDS_M e REFERENCE_THRESHOLD_M
14	Drenagem e anel	Aplicação	DRAINAGE_REF_KM2 e INSET_MARGIN_M
14	O qualificador	Aplicação	qualifier_text, sobre a troca de SRTMGL1 por alos-dem
14	A figura 14.1	Livro	figuras/figuras.py, que busca os quatro produtos pelo sidecar/dem.py e roda flood.measure
14	O cache dela	Livro	figuras/dados/envoltoria-taquari.npz
14	O estudo de origem	Linha	E-hand-flood-baseline, da linha <i>TERRA-Research</i>

Capítulo 15 *Recurso solar no ponto*

15	A ação	Aplicação	action_solar_resource em sidecar/infer.py
15	A cadeia	Aplicação	sidecar/solar.py, cuja abertura declara a grade e a calibração de rendimento
15	A série	Aplicação	fetch, annual_totals, monthly_climatology e clear_sky_index
15	A geometria	Aplicação	prepare_hourly, transpose e sweep_tilt
15	O rendimento	Aplicação	p_v_yield_frame e modelled_performance_ratio
15	O cache	Aplicação	cached_power_series e power_cell_key, em sidecar/infer.py

Tabela B.2, continuação

Cap.	O que	Onde vive	Onde está
15	O estudo de origem	Linha	o estudo de recurso solar da linha <i>TERRA-Research</i> , sobre três propriedades do oeste do Paraná
15	As figuras 15.1 e 15.2	Livro	figuras/figuras.py, que lê as tabelas de climatologia e de aferição desse estudo
15	A tabela 15.1	Livro	mede_tolerancia_inclinacao no mesmo arquivo, sobre a varredura do estudo
15	Referências	Publicado	Perez et al. (1990) para a transposição, Faiman (2008) para a temperatura de módulo, Dobos (2014) para o modelo fotovoltaico, Marion (2017) para a incidência difusa, Holmgren et al. (2018) para as implementações, Kopp e Lean (2011) para a constante solar, Doelling et al. (2016) para a radiação e Gelaro et al. (2017) para a meteorologia
Capítulo 16 <i>O modelo de energia e a cascata de perdas</i>			
16	A ação	Aplicação	action_energy_model em sidecar/infer.py
16	O módulo	Aplicação	sidecar/energy.py, que não traz fonte de dado nova e consome a cadeia do capítulo 15
16	As três razões	Aplicação	resolve_performance_ratio e modelled_factors. A fronteira de cada produto é guardada por _require_resolved
16	A cascata	Aplicação	loss_waterfall
16	A degradação	Aplicação	degradation_factor
16	O rastreamento	Aplicação	tracking_comparison, _published_land_use e _parity_ground_coverage
16	O perfil	Aplicação	generation_profile
16	A densidade	Aplicação	CAPACITY_DENSITY_BASES e resolve_capacity_density
16	A excedência	Aplicação	exceedance_table
16	A área e a planta	Aplicação	plant_energy, largest_contiguous_area_ha e _applied_shading_derate
16	As figuras 16.1 e 16.2	Livro	figuras/mede_energia.py, que roda a cadeia sobre a série horária guardada pelo estudo de recurso solar da linha <i>TERRA-Research</i> , e figuras/figuras.py, que desenha o resultado
16	Referências	Publicado	Dobos (2014) para o modelo fotovoltaico e os termos de perda, Faiman (2008) para a temperatura de módulo, Jordan e Kurtz (2013) para a taxa de degradação, Bolinger e Bolinger (2022) e Ong et al. (2013) para as densidades de capacidade e de energia por área, e a norma IEC 61724-1 para a convenção de razão de desempenho, que a define contra a irradiação no plano do módulo